

ci2.3.430Filtracja krawędzi o małym gradiencie jasnościsubsection.2.3.4

Politechnika Śląska
Wydział Automatyki, Elektroniki i Informatyki
kierunek: informatyka

Mateusz Trzeciak

Określenie wieku twarzy na podstawie tekstury

praca dyplomowa magisterska

promotor: dr hab. inż. Karolina Nurzyńska

Gliwice, listopad 2019

załącznik nr 2 do zarz. nr 97/08/09

Oświadczenie

Wyrażam zgodę / Nie wyrażam zgody* na udostępnienie mojej pracy
dyplomowej / rozprawy doktorskiej*.

Gliwice, dnia 2 listopada 2019

.....
(podpis)

.....
(poświadczenie wiarygodności
podpisu przez Dziekanat)

* podkreślić właściwe

Oświadczenie promotora

Oświadczam, że praca „Określenie wieku twarzy na podstawie tekstury” spełnia wymagania formalne pracy dyplomowej magisterskiej.

Gliwice, dnia 2 listopada 2019

.....
(podpis promotora)

Spis treści

1	Wstęp	1
2	Metoda bazowa - wskaźnik zmarszczek	5
2.1	Metoda wykrywania twarzy	8
2.1.1	Przestrzenie barw oraz skala szarości	11
2.1.2	Metoda detekcji twarzy	14
2.2	Wyznaczanie stref	21
2.3	Wykrywanie zmarszczek - detektor Canny	26
2.3.1	Redukcja szumów na obrazie filtrem Gaussa	28
2.3.2	Szukanie gradientów jasności	28
2.3.3	Zastosowanie techniki zmniejszania grubości krawędzi	29
2.3.4	Filtracja krawędzi o małym gradiencie jasności	30
2.3.5	Filtracja poprzez histerezę	30
2.4	Wyliczanie wrinkle feature	31
2.5	Algorytm analizy danych ze zbioru trenującego	32
2.6	Grupowanie danych - Fuzzy C-Means oraz wyznaczanie wieku	33
3	Modyfikacje metody bazowej	37
3.1	Odjęcie wybranej strefy	37
3.1.1	Zmiana algorytmu względem metody bazowej	38
3.2	Zastosowanie metody HOG	38
3.2.1	HOG - Zastosowanie w projekcie	44
3.3	Metoda HOG oraz algorytm KNN	45
3.3.1	Zastosowanie w projekcie	45
3.3.2	Grupowanie KNN	46

4	Badania	51
4.1	Środowisko badań	51
4.2	Rozmiar obrazu	52
4.3	Wykrywanie zmarszczek przez detektor Canny oraz Histogram of Oriented Gradients	55
4.4	Statystyki z działania programu	58
4.5	Skuteczność poszczególnych metod szacowania wieku	60
4.5.1	Metoda bazowa	61
4.5.2	Odjęcie strefy 2	62
4.5.3	Metoda HOG	63
4.5.4	Metoda HOG + KNN	64
5	Podsumowanie	67

Rozdział 1

Wstęp

Wiek jest cechą, którą niełatwo człowiekowi odczytać z czyjejś twarzy. Dla komputera rozpoznawanie wieku jest trudniejsze niż dla człowieka. Dlatego do wyznaczania wieku z pomocą programu komputerowego należy podchodzić z dystansem. Mimo trudności programiści i naukowcy udoskonalają algorytmy, tak aby ocena wieku danej osoby była coraz dokładniejsza.

Istnieje wiele sposobów wyznaczania wieku. Większość metod skupia się na analizie tekstury twarzy. Idąc dalej - z obrazu danej osoby musi zostać wykryta twarz. Wykrycie twarzy na obrazie jest możliwe dzięki algorytmom segmentacji obrazu. Segmentacja obrazu jest stosowana w wizji komputerowej i polega na wyodrębnieniu z obrazu jakichś szczegółów. Mogą to być na przykład osoby, pojazdy, przedmioty itp. (rys. 1.1)

Można znaleźć wiele witryn internetowych, które udostępniają interfejsy programistyczne umożliwiające zaimplementowanie rozpoznawania wieku z obrazu. Istnieją algorytmy przetwarzania obrazu, które oprócz wieku wyznaczają z pewnym prawdopodobieństwem płeć danej osoby. Oprócz płci mogą one także wyznaczyć emocję oraz czy dana osoba nosi okulary.

Z weryfikacją wieku danej osoby można się spotkać przed wejściem do niektórych miejsc, takich jak klub nocny. Większość osób musi okazać ważny dowód osobisty, co generuje duże kolejki do wejścia. Aplikacje analizujące wiek na podstawie obrazu twarzy z kamery przed wejściem do takich miejsc znacząco usprawniłyby weryfikację wieku. Rozpoznawanie wieku może być



Rysunek 1.1: Przykład rozpoznawania osób na obrazie [26].

wykorzystywane przy analizie średniego wieku ludzi w jakimś miejscu np. podczas demonstracji.

Wiele gier posiada treści nieodpowiednie dla młodszych użytkowników. Możliwe jest stosowanie technologii wykrywania wieku użytkownika przed udostępnieniem mu treści, która wymaga odpowiedniego wieku.

Można znaleźć o wiele więcej potencjalnych zastosowań przetwarzania obrazu oraz rozpoznawania wieku na podstawie tekstury (obrazu) twarzy. Z biegiem lat z pewnością będzie można zauważyć dalszy rozwój tej dziedziny, która opiera się w głównej mierze na sztucznej inteligencji [28].

Cel i zakres pracy

Celem niniejszej pracy jest stworzenie algorytmu do szacowania wieku. Bazą dla przeprowadzonych badań było odtworzenie pracy „Age Estimation from Face Image using Wrinkle Features” [24]. Metodę w niej zawartą poddano następnie kilku modyfikacjom.

Zakres pracy obejmuje następujące zagadnienia:

- Implementacja algorytmu z pracy [24], w dalszej części pracy określa-

nego jako metoda oryginalna lub metoda bazowa;

- Zaproponowanie kilku modyfikacji oryginalnej metody;
- Opis algorytmów oraz zmian w stosunku do oryginalnej metody;
- Przeprowadzenie badań w celu rozstrzygnięcia, który algorytm jest najskuteczniejszy w działaniu;
- Wyciągnięcie wniosków z przeprowadzonych badań.

W rozdziale 2 zaprezentowano algorytm szacowania wieku oparty na oryginalnej metodzie. W pierwszej sekcji 2.1 skupiono się na metodach wykrywania twarzy wraz z opisem metody wykrywania w bazowym algorytmie. Następnie w sekcji 2.2 zaprezentowano sposób wyznaczania stref zmarszczkowych z oryginalnej metody. W kolejnej sekcji 2.3 przedstawiono sposób detekcji zmarszczek na twarzy implementowany w metodzie bazowej. Przedostatnia sekcja rozdziału drugiego 2.5 prezentuje sposób analizy zależności pomiędzy wskaźnikiem zmarszczek, a wiekiem danej osoby. W ostatniej sekcji 2.6 tego rozdziału przedstawiono algorytm grupowania danych niezbędny do oszacowania wieku.

W kolejnym rozdziale 3 opisuje 3 modyfikację oryginalnej metody. Oprócz sposobu implementacji danych modyfikacji czytelnik zostaje zapoznany z teoretycznymi podstawami wykrywania zmarszczek za pomocą metody HOG (ang. Histogram of Oriented Gradients) oraz szacowania wieku dzięki algorytmowi KNN (ang. k-nearest neighbors).

W przedostatnim rozdziale 4 przedstawiono sposób realizacji badań oraz ich wyniki. W ostatnim rozdziale 5 podsumowano niniejszą pracę.

Rozdział 2

Metoda bazowa - wskaźnik zmarszczek

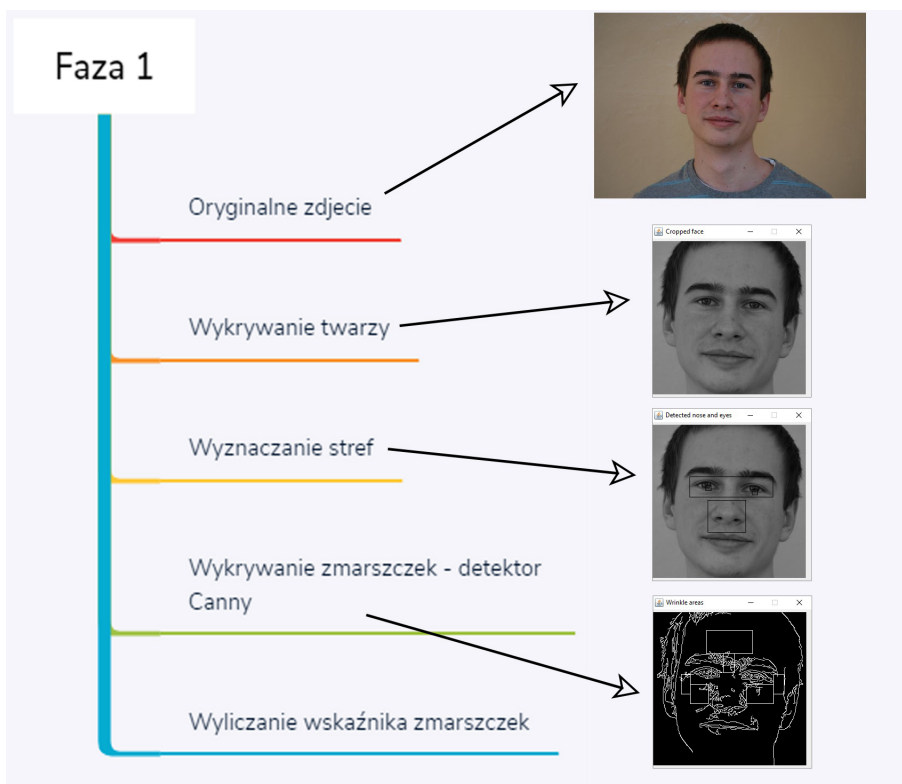
Istnieje wiele metod wyznaczania wieku z obrazu twarzy. Jedna z pierwszych metod szacowania wieku opierała się na wyznaczaniu proporcji twarzy, a następnie na detekcji i interpretacji zmarszczek. Była ona w stanie ze stu-procentową poprawnością wyznaczyć, czy dana osoba jest osobą dorosłą, czy dzieckiem [31].

W kolejnych latach algorytmy i techniki szacowania wieku były udoskonalane. Badano wpływ starzenia się osób na wygląd skóry. Oprócz naturalnych zmian skóry pod wpływem jej starzenia się należało uwzględnić także inne czynniki, do których należą między innymi płeć, poziom stresu, czy ekspozycja na działanie środowiska zewnętrznego. Badania tego rodzaju opisano w pracy [1] A. Lanitis, Ch. J. Taylor oraz T. F. Cootes. Ponadto w tej pracy zaprezentowano algorytm rozpoznawania płci, emocji czy osób na podstawie obrazu twarzy.

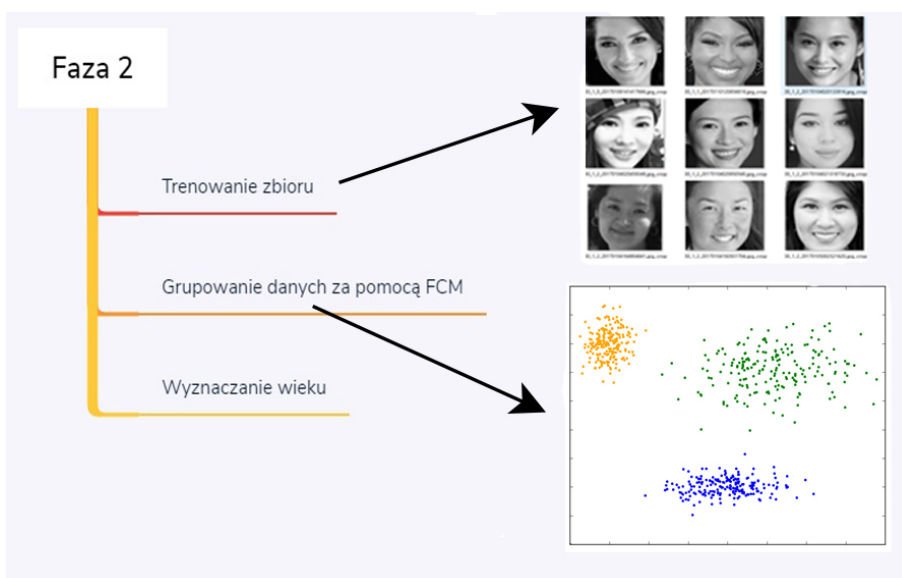
W kolejnych latach zaczęto przeprowadzać porównania cech twarzy tej samej osoby w różnym wieku. Różnice w powyższych cechach posłużyły do zbudowania statystyki zmian cech twarzy wraz ze starzeniem się. Taka analiza została zaprezentowana w pracy [21] N. Ramanathan oraz R. Chellappa. Rozwinięciem tego pomysłu była praca [30] X. Geng, Z. Zhou i K. Smith-Miles. W tym artykule porównywano sekwencje wielu zdjęć twarzy jednej

osoby. Zdjęcia przedstawiały twarz w różnym wieku. Te badania pozwoliły na zbudowanie wzorca starzenia się twarzy. Z kolei M.M. Dehshibi oraz A. Bastanfard w swojej pracy [8] analizują proporcje twarzy oraz ilość zmarszczek przy szacowaniu wieku. Praca [14] autorstwa Vladimira Khryashcheva, Alexandra Ganina, Olgi Stepanovej oraz Antona Lebedeva zawiera podsumowanie technik szacowania wieku. Wynika z niego, że do wyodrębniania cech z twarzy stosuje się BIF(ang. biologically inspired features). Powyższa metoda została zaprezentowana w książce [?] Guodong Guo i in. Mniej popularne metody analizujące cechy twarzy to filtry Gabora oraz LBP (ang. local binary patterns) [?].

W metodzie bazowej, która została opisana w artykule [24], wykrywanie wieku dzieli się na kilka faz. Na początku należy wykryć twarz. Zastosowany algorytm wykrywania został opisany w sekcji 2.1. Następnie należy wyznaczyć strefy zmarszczkowe na twarzy. W artykule [24] udowodniono, że istnieje kilka konkretnych stref, w których następuje znacząca zmiana ilości zmarszczek wraz z wiekiem. Powyższe strefy zostały wymienione w sekcji 2.2. Sekcja 2.3 przedstawia technikę wykrywania zmarszczek znajdujących się w strefach. Wykryte zmarszczki pozwalają na obliczenie wskaźnika zmarszczek dla danej twarzy, zgodnie z opisem w sekcji 2.4. W tym miejscu kończy się faza wyznaczania wskaźnika zmarszczek dla danej osoby (rysunek 2.1). Kolejna faza jest potrzebna do znalezienia relacji pomiędzy wskaźnikiem zmarszczek a wiekiem. Do tego celu należy zastosować algorytm trenujący, który został opisany w sekcji 2.5. Wynikiem algorytmu trenującego jest zbiór danych, który należy pogrupować, tak jak to opisano w sekcji 2.6. Ostatnią fazą algorytmu jest wykrywanie wieku na podstawie wyników działania FCM (ang. Fuzzy C-Means) - sekcja 2.6 (rysunek ??).



Rysunek 2.1: Faza 1 algorytmu



Rysunek 2.2: Faza 2 algorytmu

2.1 Metoda wykrywania twarzy

W literaturze można odnaleźć wiele metod wykrywania twarzy. Istnieje kilka podejść aby skutecznie wykrywać twarz na danym obrazie [25]:

- metoda oparta na nauce (ang. knowledge - based method):

Metoda oparta na nauce kieruje się wiedzą na temat wyglądu twarzy, a bardziej precyzyjnie chodzi o charakterystyczne cechy, dzięki którym na zdjęciu można wyodrębnić obszar twarzy. Mowa tutaj o cechach takich jak kształt twarzy, kolor, miejsca o różnej jasności czy specyficzne krawędzie tworzone np. przez usta.

- metoda niezmienności cech (ang. features invariant method):

W metodzie niezmienności cech wyszukuje się strukturalne cechy twarzy, które są widoczne w każdych warunkach oświetleniowych. Ponadto te cechy są widoczne bez względu na punkt widzenia, nawet jeśli twarz jest przedstawiona z profilu czy przechylona pod kątem.

- metoda dopasowania szablonu twarzy (ang. template matching method):

Metoda dopasowania szablonu twarzy wykorzystuje kilka standardowych wzorów opisujących twarz. Na wejściu algorytmu obraz jest porównywany z tymi wzorami, a na wyjściu dostajemy informację, w jakim stopniu obraz jest dopasowany do ogólnego szablonu twarzy.

- metoda bazująca na wyglądzie (ang. appearance - based method):

Ideą metody bazującej na wyglądzie jest analiza dużego zbioru obrazów twarzy, tak aby wychwycić zmienność ich cech. Tak wytrenowany model jest później wykorzystywany do wykrywania twarzy.

Należy jednak zauważyć, że w procesie ekstrakcji twarzy z obrazu mogą wystąpić liczne problemy. [25]. Jednym z nich jest nieodpowiednia poza. Wiąże się to z różnymi ustawieniami twarzy wobec aparatu fotograficznego lub kamery. Twarz może być nachylona, przechylona lub odchylona. Inaczej

mówiąc, może mieć różne położenie w trzech wymiarach, a niektóre części twarzy lub jej cechy mogą zostać przysłonięte. Im mniej cech widocznych na twarzy, tym mniej danych, które algorytm może z niej wyodrębnić, a im mniej danych, którymi algorytm operuje, tym mniejsze prawdopodobieństwo prawidłowego wykrycia twarzy. Niektóre twarze mogą zawierać pewne wyróżniające je cechy takie jak broda, blizny czy okulary. Różnorodność tych cech także wpływa na efektywność wykrywania twarzy.

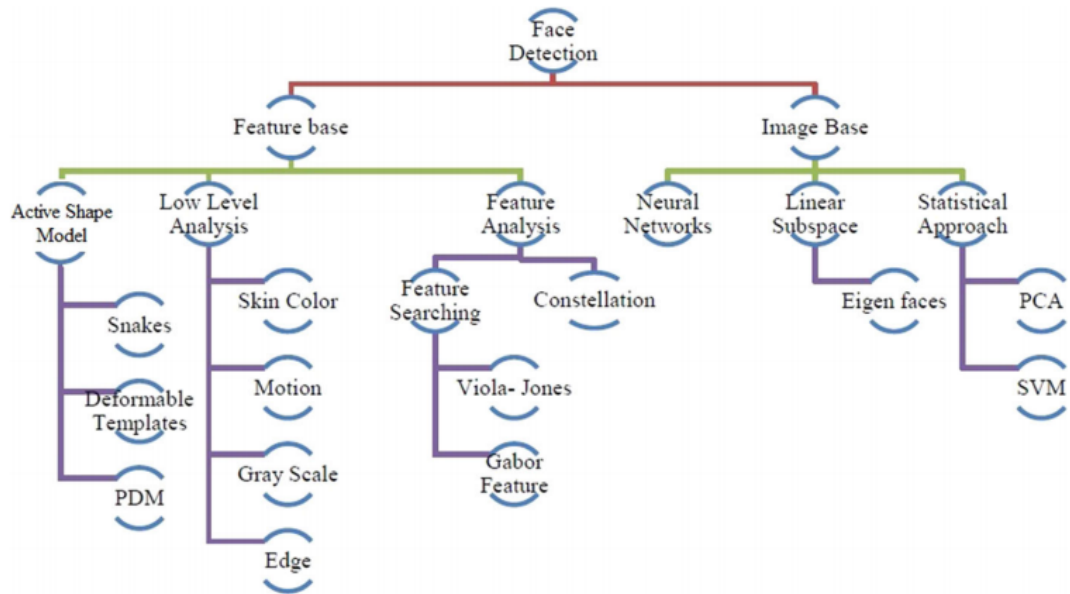
Zdarza się, że twarz zostaje częściowo przysłonięta przez jakiś inny obiekt. Na przykład na zdjęciu, które obejmuje grupę wielu osób, część danej twarzy może być przysłonięta przez inną twarz. Takie przysłonięcie przez inny obiekt wiąże się z utratą informacji o części twarzy, co zmniejsza prawdopodobieństwo prawidłowego jej wykrycia.

Ilość zmarszczek na twarzy jest zmienna, w zależności od wyrazu mimicznego. Przy różnych minach zmienia się kształt ust, a czasem w wyniku pracy mięśni uwydatniają się na twarzy ostre krawędzie. Widoczne mogą być różne pofałdowania skóry.

Kolejnym istotnym elementem jest oświetlenie twarzy. Gdy twarz oświetlona jest tzw. ostrym światłem, występują na niej cienie i światła określane jako ostre (obraz 2.3). W tym przypadku ryzyko utraty szczegółów oświe-



Rysunek 2.3: Przykład twarzy oświetlonej ostrym (twarz po lewej) oraz miękkim światłem [10].



Rysunek 2.4: Różne techniki wykrywania twarzy [3].

tlanej twarzy jest większe. Kiedy twarz jest skierowana na wprost słońca, z dużym prawdopodobieństwem można stwierdzić, że zostanie oświetlona ostrym światłem. Z kolei miękkie światło jest generowane na przykład przez zachmurzone niebo. Istotne jest także źródło światła, które może być punktowe lub rozproszone. Przy punktowym źródle światła cała twarz jest okryta jednolitym cieniem, którego intensywność zależy od rodzaju światła. Natomiast przy świetle rozproszonym intensywność cieni jest mniejsza. Na rys. 2.4 przedstawione są różne techniki wykrywania twarzy.

Jak widać metod wykrywania twarzy jest sporo, a szczegółowe omówienie każdej z nich nie byłoby merytorycznie uzasadnione. Poniżej zostaną przytoczone dwie metody wykrywania twarzy. Dodatkowo zostanie omówiona metoda, która posłużyła do wykrywania twarzy w niniejszej pracy.

W pracy [15] przedstawiono opisaną w skrócie poniżej technikę wykrywania twarzy. W pierwszym etapie procesu obszary, gdzie może znajdować się ludzkie oko, są wykrywane przez przeprowadzenie testów na zacienionych rejonach obrazu. Pary takich obszarów wyodrębnia się na podstawie algorytmu genetycznego, aby następnie wyznaczyć możliwy obszar twarzy. Dla

każdego obszaru mierzy się wartość dopasowania na podstawie jego projekcji na wektory własne, obliczone dla obszarów twarzy, tzw. eigenfaces. Aby wiarygodność wykrywania była wyższa, każdy możliwy obszar twarzy normalizuje się pod kątem oświetlenia. Proces ten powtarza się pewną ilość razy, a następnie do dalszej weryfikacji są wybierane możliwe obszary twarzy o wysokiej wartości dopasowania. Na tym etapie mierzy się symetrię twarzy oraz sprawdza się, czy na każdym wybranym obszarze istnieją rysy twarzy. Rysy określa się przez ewaluację rzeźby topograficznej - wystających i wklęsłych elementów różnych regionów obszaru twarzy, poddanego uprzednio normalizacji. Algorytm jest w stanie wykryć obszar twarzy także wtedy, gdy głowa jest przechylona.

W roku 1997 w pracy [6] opisano metodę wykrywania twarzy bazującą na wykrywaniu cechy, jaką jest kolor skóry. Zarówno dla człowieka, jak i dla maszyny kolor skóry jest najbardziej widoczną cechą twarzy. Ponadto kolor jest przetwarzany znacznie szybciej niż inne cechy. Przy dobrych warunkach oświetleniowych ustawienie twarzy nie ma wpływu na skuteczność wykrywalności twarzy opisywaną metodą.

Niezależnie od wybranej metody mogą wystąpić problemy z poprawnym wykryciem twarzy. Jednym z nich jest problem wykrywalności twarzy przy nierównomiernym oświetleniu. Problem pojawia się także, gdy na obrazie widoczny jest obszar skóry spoza twarzy, np. z rąk. Warto zaznaczyć, że kolor twarzy na obrazie jest zależny od względnego kierunku oświetlenia. Obszar twarzy w omawianym algorytmie jest wykrywany poprzez normalizację histogramu kolorów. Normalizacja jest potrzebna do redukcji wpływu natężenia oświetlenia na kolor.

Algorytm Haar Cascade jest jedynym algorytmem do wykrywania twarzy zaimplementowanym w bibliotece OpenCV, dlatego został wykorzystany w procesie badawczym. Algorytm został bliżej przedstawiony w książce [23] w 2001 roku i składa się z trzech podstawowych faz, których dokładny opis znajduje się w sekcji 2.1.2.

2.1.1 Przestrzenie barw oraz skala szarości

Każdy piksel w trybie kolorowym ma określoną reprezentację barwy z określonego modelu. Najczęściej są to 3 lub 4 wartości [12]. Do przestrzeni barw zaliczają się:

- CIEXYZ
- CMYK
- RGB

W dziedzinie rozpoznawania obrazów najczęściej barwy są reprezentowane przez przestrzeń barw RGB [12]. Przestrzeń kolorów RGB składa się z trzech kanałów [13]:

- R - czerwonego (z angielskiego Red)
- G - zielonego (z angielskiego Green)
- B - niebieskiego (z angielskiego Blue)


Barwy mieszane są poprzez syntezę addytywną. W przeciwieństwie do syntezy subtraktywnej, barwa wynikowa powstaje tu poprzez sumowanie wiązek światła widzialnego o różnych długościach [12]. Każdy piksel opisany za pomocą przestrzeni barw RGB ma trzy 8-bitowe wartości reprezentujące każdy kanał. Spotykane są 12- lub 16-bitowe reprezentacje kanałów, jednak 8-bitowa jest najpopularniejsza. Dla 8-bitowych kanałów wartość „0” danego kanału oznacza brak jasności, natomiast „255” maksymalną jasność. Poprzez mieszanie jasności tych trzech kanałów można uzyskać szerokie spektrum barw (rysunek 2.5).

Przykładowo kolor o reprezentacji R=153 G=217 B=234 przedstawiono na rysunku 2.6

Kolor (rysunek 2.6) może być też reprezentowany w kodzie szesnastkowym #99D9EA. Każda wartość heksadecymalna odpowiada kolejno kanałowi R, G, B.



Rysunek 2.5: Mieszanie kanałów RGB [20].



Rysunek 2.6: Kolor R=153 G=217 B=234.


Obraz może też być przedstawiony za pomocą odcieni jednej barwy. Taki obraz nazywa się obrazem monochromatycznym. Najczęściej stosowaną barwą w takich obrazach jest szarość [12].

Istnieją 3 metody konwersji obrazu z przestrzeni RGB na monochromatyczny [20].

- największej jasności
- średnia
- luminancji

Metoda największej jasności konwertuje na skalę szarości wg wzoru 2.1.

$$\frac{(\max(R, G, B) + \min(R, G, B))}{2} \quad (2.1)$$



Rysunek 2.7: Filtr Haara a) krawędziowy b) liniowy c) szachownica [2]

Metoda średnia bazuje na wzorze 2.2, natomiast metodę luminancji ilustruje wzór 2.3.

$$\frac{(R + G + B)}{3} \quad (2.2)$$


$$0,21R + 0,72G + 0,07B \quad (2.3)$$

W niniejszej pracy zastosowano konwersję za pomocą metody średniej.

2.1.2 Metoda detekcji twarzy

Haar Cascade jest algorytmem służącym do wykrywania obiektów na obrazach. Został stworzony przez Paula Violę oraz Michaela Jonesa w 2001 roku [23]. Opiera się na zbudowaniu kaskadowej funkcji za pomocą trenowania wielu zdjęć. Zdjęcia są dzielone na dwie kategorie - pozytywne oraz negatywne. Na zdjęciach klasyfikowanych jako pozytywne istnieje obiekt, który ma zostać wykryty, natomiast na zdjęciach negatywnych nie ma tego obiektu.

Ekstrakcja cech w algorytmie Violi i Jonesa jest realizowana przez filtry Haara. Są to prostokątne okienka nakładane na obraz, które analizują jasność pikseli (rysunek 2.7).



Rysunek 2.8: Filtr Haara nałożony na krawędź twarzy [2]

Przed zastosowaniem filtru Haara obraz musi zostać przekształcony do skali szarości. W niniejszej pracy należało przekształcić każdy obraz z trybu kolorowego na monochromatyczny, co opisano w sekcji 2.1.1.

Filtry mają postać białych i czarnych prostokątów pogrupowanych w okna. Wyznaczana jest suma jasności pikseli w obu rodzajach prostokątów, a następnie dla każdego okna obliczana jest różnica pomiędzy białymi a czarnymi. Opisany algorytm ma zastosowanie w wykrywaniu krawędzi. Na granicy krawędzi istnieje różnica w jasności pikseli (rysunek 2.8).

W celu poprawy efektywności sumowania pikseli stosowane są rozwiązania zwane w języku angielskim *summed-area table* [28]. *Summed-area table* jest również nazywana w literaturze *integral image*, czyli obrazem scałkowanym. Ideą obrazu scałkowanego jest, aby każdy obraz został przekształcony w tabelę, w której każdy element x, y tej tabeli odpowiada sumie jasności wszystkich pikseli według wzoru 2.4.

$$I(x, y) = \sum_{x' \leq x \cap y' \leq y} i(x', y') \quad (2.4)$$

gdzie $I(x, y)$ jest wartością na pozycji x, y w tabeli (tabela obrazu scałkowanego).

Image

5	2	5	2
3	6	3	6
5	2	5	2
3	6	3	6

Rysunek 2.9: Tabela jasności poszczególnych pikseli przed zastosowaniem całkowania [4]

Summed Area Table

5	7	12	14
8	16	24	32
13	23	36	46
16	32	48	64

Rysunek 2.10: Filtr Haara nałożony na krawędź twarzy [4]

nego), natomiast $i(x,y)$ oznacza jasność piksela o współrzędnych x,y na obrazie.

Na rysunku 2.9 przedstawiona jest tabela prezentująca jasność pikseli przed zastosowaniem całkowania obrazu.

Po całkowaniu otrzymujemy tabelę podobną do przedstawionej na rysunku 2.10.

Sumowanie przykładowego okna (rysunek 2.11) wymaga czterech operacji (wzór 2.5).

$$\sum_{x_0 \leq x \leq x_1 \cap y \leq y_1} i(x,y) = I(D) + I(A) - I(B) - I(C) \quad (2.5)$$

gdzie lewa część równania oznacza sumę jasności pikseli zaznaczonego okna tj. na rysunku 2.11, $I(A)$ - wartość scałkowanego obrazu przy punkcie A

Summed Area Table

5	7	12	14
8	16	24	32
13	23	36	46
16	32	48	64

Rysunek 2.11: Sumowanie okna [4]

(analogicznie $I(B)$, $I(C)$, $I(D)$) - (rysunek 2.11).

W związku z powyższym obliczenie wartości dla krawędziowego filtru Haara wymaga obliczenia różnicy dwóch sum, zatem do uzyskania wyniku konieczne jest wykonanie ośmiu operacji. Reprezentacja obrazu za pomocą obrazu scałkowanego znacznie zwiększa efektywność obliczania wartości w filtrze Haara.

Liczba cech wykrywanych w danym zdjęciu za pomocą filtru Haara jest znacznie większa od liczby pikseli na obrazie [23]. Dla obrazu o wymiarach 384x288 pikseli liczba cech wynosi ponad 180000. Autorzy algorytmu stwierdzili, że dla zwiększenia jego szybkości należy wybrać małą grupę cech, które razem mogą stworzyć jeden efektywny klasyfikator obiektu. W celu wyodrębnienia tych istotnych cech zastosowano algorytm Adaboost, który został opisany poniżej.

Zbiór n obrazów do trenowania można oznaczyć tak jak we wzorze 2.6:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \quad (2.6)$$

oznacza, że obraz jest odpowiednio negatywny lub pozytywny. Następnym krokiem jest inicjalizacja wag (wzór 2.7).

$$w_{1,i} = \frac{1}{2m}, \frac{1}{2l} \quad (2.7)$$

odpowiednio dla $y_i = 0, 1$, gdzie m, l oznacza odpowiednio liczbę negatywnych oraz pozytywnych zdjęć. Następnie Dla $t = 1, \dots, T$:

1. Normalizowane są wagi (wzór 2.8):

$$w_{t,i} = \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}} \quad (2.8)$$

w_t jest rozkładem prawdopodobieństwa

2. Dla każdej cechy j , trenowany jest klasyfikator h_j , który używa tylko jednej cechy wyliczonej z filtru Haara. Błąd jest liczony następująco (wzór 2.9):

$$w_t, \epsilon_j = \sum_i w_i h_j(x_i) - y_i \quad (2.9)$$

3. Wybierany jest klasyfikator h_t z najmniejszym błędem ϵ_t .

4. Następuje aktualizacja wag (wzór 2.10):

$$w_{t+1,i} = w_{t,i} \beta_t^{1-e_i} \quad (2.10)$$

, gdzie $e_i = 0$. Jeśli x_i jest sklasyfikowane prawidłowo, wtedy $e_i = 1$, w innym wypadku $\beta_t = \frac{\epsilon_t}{1-\epsilon_t}$.


Silny klasyfikator $h(x)$ jest opisany równaniem:

$$h(x) = \begin{cases} 1 & \text{gdy } \sum_{t=1}^T \alpha_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0 & \text{w przeciwnym wypadku} \end{cases} \quad (2.11)$$

, gdzie $\alpha_t = \lg \frac{1}{\beta_t}$

Algorytm Adaboost zmniejsza ilość cech Haara z ponad stu tysięcy do kilkuset - do tych najistotniejszych cech.

Ostatnim etapem jest wytworzenie kaskady klasyfikatorów. Zwiększa ona znacznie szybkość wykrywania pożądanego obiektu na obrazie. Ideą kaskady jest zgrupowanie klasyfikatorów, które powstały w poprzednim procesie - tzw. procesie boostingu. Klasyfikatory są grupowane w okna, które są połączone ze sobą tak jak na rysunku 2.12. Okna są oznaczone jako P1, P2, ..., Pn. Gdy dane okno wykryje obiekt, przechodzi do kolejnego okna w



Rysunek 2.12: Kaskada klasyfikatorów [29].

kaskadzie. W przeciwnym wypadku algorytm przerywa działanie i na danym obrazie nie zostaje zidentyfikowany obiekt. Okna są poustawiane tak, aby każde z nich klasyfikowało obiekt z różnym prawdopodobieństwem wykrycia oraz prawdopodobieństwem błędu. Składnikami wyżej wymienionego prawdopodobieństwa jest macierz pomyłek (rysunek 2.13).

		Odpowiedź klasyfikatora	
		TAK	NIE
Istnieje obiekt?	TAK	True Positive	False Negative
	NIE	False Positive	True Negative

Rysunek 2.13: Macierz pomyłek.

Z macierzy 2.13 można odczytać, czy klasyfikator poprawnie sklasyfikował dane testowe. W macierzy zostały użyte cztery pojęcia [5]:

- TP (true positive) - poprawna klasyfikacja jako obiekt
- TN (true negative) - poprawna klasyfikacja jako nie - obiekt
- FP (false positive) - błędna klasyfikacja jako obiekt
- FN (false negative) - błędna klasyfikacja jako nie - obiekt

Prawdopodobieństwo błędu wyliczane jest ze współczynnika FPR (false positive rate) (wzór 2.12).

$$FPR = \frac{FP}{FP + TN} \quad (2.12)$$

Natomiast prawdopodobieństwo wykrycia obiektu wyliczane jest ze współczynnika TPR (true positive ratio) (wzór 2.13)

$$TPR = \frac{TP}{TP + FN} \quad (2.13)$$

Pierwsze okna posiadają klasyfikatory o słabszym TPR oraz FPR niż kolejne. Oznacza to, że prawdopodobieństwo TPR w oknie P_{x-1} jest mniejsze od tego w P_x . Natomiast prawdopodobieństwo FPR w oknie P_{x-1} jest większe od tego w P_x . Ostatnie okna mają największy współczynnik TPR oraz najmniejszy FRP ze wszystkich. Takie ustawienie okien ma na celu wstępne przepuszczenie przez okna obrazów, które z dużym prawdopodobieństwem zawierają szukany obiekt. Natomiast ostatnie okna w kaskadzie analizują niewielką część obrazu wejściowego.

Biblioteka OpenCV zawiera wytrenowane klasyfikatory, które zostały użyte w tej pracy magisterskiej. Wykorzystano je do wykrycia twarzy, ust oraz oczu. Klasyfikatory mają postać plików xml, które można znaleźć na oryginalnym repozytorium projektu OpenCv.


2.2 Wyznaczanie stref

Przed wyznaczeniem stref zmarszczkowych należy zidentyfikować na twarzy oczy oraz nos (rysunek 2.14).


Należy podkreślić, że algorytm przerywa działanie jeśli nie zostanie wykryta twarz, oczy lub nos.

Gdy zostanie wykryty obszar twarzy, oczu oraz nosa wyznaczone zostaje sześć stref zmarszczkowych (rysunek 2.15).


Strefy zmarszczkowe są umiejscowione na czole (Strefa „1”), w górnej



Rysunek 2.14: Wykryty nos oraz oczy.



Rysunek 2.15: Strefy zmarszczkowe widoczne w białych prostokątach.



Rysunek 2.16: Wyznaczenie strefy znajdującej się na czole.

części nosa (Strefa „2”), górnej części policzków (Strefa „4” i „5”) oraz w okolicach powiek (Strefa „3” i „6”). To właśnie te miejsca zostały uznane przez autorów książki „Age Estimation from Face Image using Wrinkle Features” [24] za najbardziej znaczące w detekcji wieku.

Po detekcji oczu należy zmierzyć odległość pomiędzy środkiem lewego oka (x_l, y_l) , a prawego (x_p, y_p) (wzór 2.14).

$$d = \sqrt{(x_r - x_l)^2 + (y_r - y_l)^2} \quad (2.14)$$

Odległość d służy do wyznaczanie strefy znajdującej się na czole (rysunek 2.16).

Autorzy [24] algorytmu założyli, że odległość od linii oczu do linii brwi wynosi $0,4 * d$, natomiast wymiary „strefy czoła” wynoszą $d \times 0,5d$.

Na rysunku 2.17 przedstawiono współrzędne, które są pomocne w wyznaczaniu stref zmarszczkowych.

Strefa 2 została wyznaczona dzięki znajomości położenia prawego oka, dystansu między oczami oraz strefy „1”. Każda strefa może być wyznaczona



Rysunek 2.17: Pomocnicze współrzędne do wyliczania stref zmarszczkowych.

przez jeden punkt (rysunek 2.18) oraz jej wymiary.

Współrzędna x punktu A została wyznaczona ze wzoru 2.15

$$x_A = x_6 + 0,375 \times d \quad (2.15)$$

, gdzie x_6 to współrzędna z rysunku 2.17. Natomiast d jest odległością pomiędzy oczami (wzór 2.14).


Współrzędną y punktu A opisuje wzór 2.16:

$$y_A = y_7 \quad (2.16)$$

Współrzędna y_7 analogicznie jak x_6 znajduje się na rysunku 2.17.

Zakładając, że prawe oko ma współrzędne x_o oraz y_o wysokość strefy 2 wyznaczana jest w poniższy sposób (wzór 2.17).

$$h_A = y_o - y_7 \quad (2.17)$$



Rysunek 2.18: Punkty wyznaczające położenie stref.

Natomiast szerokość strefy 2 oblicza się następująco: (wzór 2.18):

$$w_A = 0,25 * d \quad (2.18)$$

Wartość 0,25 ze wzoru 2.18 została dobrana empirycznie.

Współrzędne punktu C (strefa 4) zostają wyznaczone ze wzoru 2.19 oraz 2.20.

$$x_C = x_3 \quad (2.19)$$

$$y_C = \frac{y_4 - y_3}{2} \quad (2.20)$$

Wysokość oraz szerokość strefy 4 (wzór 2.21 oraz 2.22)

$$h_C = y_C - y_3 \quad (2.21)$$

$$w_C = x_3 - x_1 \quad (2.22)$$

Strefa 5 zawiera punkt D - wzór 2.23 oraz 2.24.

$$x_D = x_4 \quad (2.23)$$

$$y_D = y_C \quad (2.24)$$

Dla strefy 5 wyznacza się wysokość (wzór 2.25) oraz szerokość na podstawie wzoru (Wzór 2.26).

$$h_D = h_C \quad (2.25)$$

$$w_D = x_2 - x_4 \quad (2.26)$$

Strefa 3 zawiera punkt B wyznaczany ze wzorów 2.27 i 2.28

$$x_B = x_1 \quad (2.27)$$

$$y_B = \frac{y_2 - y_1}{2} \quad (2.28)$$

Wysokość (wzór 2.29) oraz szerokość (wzór 2.30) strefy 3.

$$h_B = y_C - y_B \quad (2.29)$$

$$w_B = w_C * 0,4 \quad (2.30)$$

Na samym końcu zostaje wyznaczona strefa 6. Wyznaczona zostaje współ-

rzędna E - wzór 2.31 i 2.32.

$$x_E = x_2 \quad (2.31)$$

$$y_E = y_B \quad (2.32)$$

Szerokość oraz wysokość strefy 6.

$$h_E = h_B \quad (2.33)$$

$$w_E = w_D * 0,4 \quad (2.34)$$

Należy zauważyć, że szerokość stref 3 i 6 jest pomnożona przez 0,4 szerokości odpowiednio stref 4 i 5. Wartość „0,4” została dobrana empirycznie.

2.3 Wykrywanie zmarszczek - detektor Canny

Następnym krokiem algorytmu po wyznaczeniu stref zmarszczkowych jest wyodrębnienie zmarszczek poprzez detekcję krawędzi. Istnieje wiele metod do tego celu, jednak detektor Canny jest jedną z najbardziej dokładnych i niezawodnych, dlatego został zastosowany w toku badań. Metoda ta została opracowana przez Johna F. Canny w 1986 roku. Oprócz samej implementacji algorytmu jego twórca zaprezentował teorię obliczeniową, która wyjaśnia działanie tej metody. Ponadto Canny zauważył, że wymagania dotyczące implementacji detekcji krawędzi są podobne do siebie w wielu systemach wizyjnych. W związku z powyższym jego algorytm może zostać skutecznie zastosowany w różnych systemach tego typu. Poniżej przedstawiono najważniejsze zasady, które są niezbędne do dobrej detekcji krawędzi w opisywanym algorytmie:

- Detekcja krawędzi z niskim prawdopodobieństwem błędu: Oznacza to, że algorytm powinien wykryć jak najwięcej krawędzi, które rzeczywiście

istnieją. Natomiast ilość krawędzi wykrytych błędnie powinna być jak najmniejsza.

- Precyzja detekcji: Algorytm powinien precyzyjnie zlokalizować krawędź.
- Brak redundantnych detekcji: Krawędź powinna być zlokalizowana jednokrotnie, a szum na obrazie nie powinien generować dodatkowych krawędzi.

W algorytmie detekcji Canny używa rachunku wariacyjnego. Rachunek wariacyjny to dziedzina analizy matematycznej, która analizuje przestrzenie funkcyjne i znajduje w nich ekstrema funkcjonałów. Funkcjonały natomiast przekształcają przestrzeń wektorową na liczby rzeczywiste. Zatem rachunek wariacyjny ma za zadanie pomóc w znalezieniu charakterystycznej funkcji, dla której funkcjonał przyjmuje wartość ekstremalną. Algorytm detektora jest podzielony na kilka kroków [17]:

- Redukcja szumów na obrazie filtrem Gaussa.
- Szukanie gradientów jasności.
- Zastosowanie techniki zmniejszania grubości krawędzi.
- Likwidacja krawędzi o małym gradiencie jasności.
- Filtracja poprzez histerezę.

2.3.1 Redukcja szumów na obrazie filtrem Gaussa

Szum na obrazie to piksele o losowym kolorze, jasności oraz umiejscowieniu (współrzędnych na obrazie). Takie piksele są nadmiarowymi informacjami o obrazie oraz stanowią efekt uboczny przetwarzania obrazu przez matrycę cyfrową (rysunek 2.19).

Efekt szumu jest spotykany również w fotografii analogowej. W fotografii cyfrowej szum wzrasta na skutek zwiększania czułości matrycy lub przez wzrost jej temperatury. Redukcję szumów można uzyskać stosując



Rysunek 2.19: a) Obraz z nieznaczną ilością szumów b) Obraz ze znaczną ilością szumów [27].

filtr Gaussa. Splot filtru Gaussa z obrazem daje w wyniku wygładzony obraz ze zmniejszoną ilością szumów. Filtr Gaussa może mieć różne wymiary, natomiast najczęściej stosowanym jest 5x5. Rozmiar filtra ma wpływ na wydajność wygładzania obrazu, a co za tym idzie na czułość wykrywania szumu [17].

2.3.2 Szukanie gradientów jasności

Istotnym parametrem w wykrywaniu krawędzi jest gradient jasności. Określa on jak bardzo zmienia się jasność danego piksela względem sąsiadujących pikseli. Gradient jasności otrzymany zostaje ze wzoru 2.35:

$$G = \sqrt{G_x^2 + G_y^2} \quad (2.35)$$

gdzie G_x jest zmianą jasności danego piksela w kierunku poziomym, a G_y w kierunku pionowym. Kierunek gradientu opisuje wzór 2.36

$$\Theta = \text{atan2}(G_y, G_x) \quad (2.36)$$

Krawędzie na obrazie charakteryzują się pewną zmianą jasności na danym obszarze obrazu. Krawędź na obrazie może być położona pod różnym kątem. Opisywany detektor używa czterech filtrów w celu wykrycia pionowych, poziomych oraz ukośnych krawędzi.

Kierunek gradientu jest zaokrąglony do jednego z filtrów kierunku: poziomego ($\Theta = 0^\circ$), pionowego ($\Theta = 90^\circ$) lub ukośnego ($\Theta = 45^\circ$ lub $\Theta = 135^\circ$ stopni). Każdy piksel obrazu otrzymuje wartość gradientu (wzór 2.35) oraz kierunek - zgodny z powyższym filtrem kierunku. W wyniku tego działania otrzymuje się obraz gradientowy [17].

2.3.3 Zastosowanie techniki zmniejszania grubości krawędzi

Zmniejszanie grubości krawędzi służy do filtracji krawędzi powstałych po poprzednim kroku. Krawędzie wykryte za pomocą gradientu są rozmyte. Dzięki technice zmniejszania grubości można odszukać na małym obszarze gradienty o największej wartości, które identyfikują najostrzejsze krawędzie. Wszystkie inne, o mniejszej wartości, są ignorowane. Algorytm operuje na obrazie gradientowym powstałym jako wynik działania algorytmu opisanego w sekcji 2.3.2 Działa on następująco:

Odczytana zostaje wartość gradientu oraz jego kierunek dla danego piksela. Następnie wartość gradientu porównuje się z wartościami gradientu dla dwóch sąsiednich pikseli. Pierwszy sąsiedni piksel jest wyznaczony przez aktualny kierunek gradientu, a drugi przez kierunek przeciwny. Jeśli wartość danego piksela jest największa spośród pikseli wzdłuż wyżej wymienionych linii, to dany piksel należy do najostrzejszej krawędzi [17].

2.3.4 Filtracja krawędzi o małym gradiencie jasności

Zastosowanie techniki zmniejszania grubości krawędzi pozostawia na obrazie wiele krawędzi, które są wygenerowane przez szum i zmiany kolorów. Kolejnym krokiem jest filtracja powyższych krawędzi, gdyż są one nadmiarowe. W tym celu ustawiany jest pewien próg, zwany progiem małym. Oprócz

progu małego ustawiany jest również próg duży w celu wyodrębnienia krawędzi o wysokim gradiencie jasności. Jeśli wartość gradientu dla danej krawędzi jest mniejsza od progu małego, to zostaje ona usunięta. W przypadku, gdy wartość jest większa od progu małego, ale mniejsza od progu dużego, dana krawędź zostaje oznaczona jako słaba. Krawędź oznacza się jako mocną, gdy wartość gradientu dla niej jest większa od wartości progu dużego [17].


2.3.5 Filtracja poprzez histerezę

W wyniku działania algorytmu do tej pory zostały uzyskane słabe oraz mocne krawędzie. Mocne krawędzie zostaną oznaczone jako prawdziwe krawędzie znajdujące się na obrazie. Słabe krawędzie mogą być częścią mocnych krawędzi, ale mogą również zostać wygenerowane przez szum lub zmiany kolorów. Krawędzie tego typu nie są prawdziwymi krawędziami w obrazie, więc w ostatnim kroku algorytmu powinny zostać przefiltrowane. Słabe krawędzie, które są powiązane z mocnymi znajdują się w najbliższym sąsiedztwie mocnych krawędzi. W celu odnalezienia tych powiązań pomiędzy krawędziami zostaje zastosowana analiza spójności krawędzi. Jeśli zostaje zidentyfikowane powiązanie pomiędzy mocną, a słabą krawędzią, to słabą krawędź pozostawia się w obrazie. W przypadku, gdy słaba krawędź nie jest powiązana z żadną mocną krawędzią - zostaje usunięta [17].

2.4 Wyliczanie wrinkle feature

W wyniku działania detektora Cannego, który został opisany w sekcji 2.3 wygenerowany zostaje obraz binarny z wyodrębnionymi krawędziami. Obraz binarny zawiera piksele o dwóch wartościach jasności pikseli. Piksel może być albo biały albo czarny. Krawędzie można rozpoznać jako białe piksele, natomiast czarne piksele oznaczają brak krawędzi (rysunek 2.20).

Na rysunku 2.20 widoczne są krawędzie, które identyfikują owal twarzy. Ponadto widoczne są poszczególne części twarzy tj. nos, oczy, brwi. Można także zauważyć dodatkowe krawędzie w strefach zmarszczkowych (sekcja 2.2), które identyfikują zmarszczki. W metodzie bazowej ilość białych pikseli w



Rysunek 2.20: a) Oryginalny obraz b) Obraz z wykrytymi krawędziami.

strefach zmarszczkowych jest wprost proporcjonalna do ilości zmarszczek na twarzy danej osoby.

Z każdej strefy zmarszczkowej obliczany jest stosunek ilości białych pikseli do wszystkich pikseli (wzór 2.37).

$$W_{s1} = \frac{PB_{s1}}{PW_{s1}} \quad (2.37)$$

, gdzie W_{s1} jest stosunkiem białych pikseli do wszystkich w strefie 1, PB_{s1} - suma białych pikseli w strefie 1, PW_{s1} - suma wszystkich pikseli w strefie 1. Analogicznie obliczane są stosunki pikseli dla pozostałych stref. Ostatnim etapem jest sumowanie wszystkich stosunków pikseli (wzór 2.38).

$$WZ = W_{s1} + W_{s2} + W_{s3} + W_{s4} + W_{s5} + W_{s6} \quad (2.38)$$

, gdzie WZ to wskaźnik zmarszczek - parametr określający ilość zmarszczek dla danej osoby.

2.5 Algorytm analizy danych ze zbioru trenującego

W celu skonstruowania programu wyznaczającego wiek na podstawie tekstury należy wcześniej zbadać zależność ilości zmarszczek od wieku. W tym celu należy posiadać odpowiednią bazę zdjęć, na których można przeprowadzić wyżej wspomniane badania.

Jest wiele darmowych źródeł obrazów twarzy. Najczęściej używane bazy to FG-NET oraz MORTH II, które zawierają dziesiątki tysięcy zdjęć. Zdjęcia są różnej jakości i nie każda baza zdjęć nadaje się do konkretnych badań [14]. Przy realizacji tej pracy wykorzystana została baza UTKFace, ponieważ wszystkie zgrupowane w niej obrazy przedstawiają twarze w pozycji frontalnej. Dodatkowo ścieżka pliku każdego obrazu zawiera informacje na temat rzeczywistego wieku, co pozwala w łatwy sposób zweryfikować poprawność algorytmu. W związku z powyższym z każdego zdjęcia z tej bazy otrzymywano dwie informacje - rzeczywisty wiek danej osoby oraz współczynnik zmarszczek. Następnie dla całej bazy wygenerowano zbiór danych, który w dalszej kolejności był odpowiednio analizowany w celu sprawdzenia zależności pomiędzy współczynnikiem zmarszczek, a wiekiem. Wyżej wymieniony proces nazywany jest także trenowaniem zbioru danych.

Autorzy algorytmu w celu analizy uprzednio wygenerowanego zbioru danych wykorzystali algorytm grupowania - Fuzzy C-Means. W wyniku działania tego algorytmu otrzymuje się dane, dzięki którym na podstawie współczynnika zmarszczek można oszacować wiek [24].

2.6 Grupowanie danych - Fuzzy C-Means oraz wyznaczanie wieku

Grupowanie danych, zwane również klasteryzacją, jest szeroko stosowane w uczeniu maszynowym, rozpoznawaniu wzorców, analizie obrazu, bioinformatyce, kompresji danych czy w grafice komputerowej. Polega na podzieleniu dużego zbioru danych na grupy. Powyższe grupy zawierają dane, które są po-

dobne do siebie [9].

Klasteryzacja nie jest algorytmem, lecz zadaniem, które może zostać wykonane na wiele sposobów. Jest również iteracyjnym procesem odkrywania danych w celu odnalezieniu relacji pomiędzy nimi.

Odpowiedni algorytm grupowania i ustawienia parametrów (w tym parametrów takich jak funkcja odległości lub liczba oczekiwanych grup) zależą od zestawu danych i sposobu wykorzystania wyników. Dane nieraz muszą zostać przefiltrowane lub potrzebna jest zmiana parametrów grupowania w celu osiągnięcia zamierzonego efektu [9].

Algorytmy różnią się pod względem implementacji grupowania czy wydajności. Najczęściej grupa jest definiowana przez jak najmniejszą odległość pomiędzy jej członkami. Zarazem odległość pomiędzy członkami grupy jest głównym parametrem klasteryzacji hierarchicznej. Istnieje również wiele innych modeli grupowania. Jednym z nich jest model centroidowy, który zakłada, że każda grupa jest zdefiniowana przez jeden wektor, posiadający wartość średnią. Istnieją też modele, które opierają się na sieciach neuronowych. Ich podstawą jest założenie, że dane grupują się za pomocą nienadzorowanych sieci neuronowych. Spotykany jest także model oparty o rozkłady statystyczne.

Klasteryzacja może być twarda lub miękka. Twarda klasteryzacja oznacza, że każdy element danych może należeć tylko do jednej grupy. Natomiast w przypadku miękkiej klasteryzacji każdy element danych może w pewnym stopniu należeć do każdej z grup. Autorzy algorytmu szacowania wieku opisywanego w niniejszej pracy zastosowali grupowanie metodą Fuzzy C-means. Należy ona do grupy modeli centroidowych [9]. W Fuzzy C-means zastosowano klasteryzację miękką.

Algorytm Fuzzy C-means został stworzony w 1973 przez J. C. Dunn. Po raz pierwszy został opisany w książce „A Fuzzy Relative of the ISODATA Process and Its Use in Detecting Compact Well-Separated Clusters”.

Klasteryzacja Fuzzy C-means dzieli zbiór X (wzór 2.39):

$$X := \{x_1, x_2, x_3, \dots, x_n\} \subset \mathbb{R} \quad (2.39)$$

W parametrze algorytmu zostaje ustalona liczba grup c . Każda grupa posiada charakterystyczną wartość nazywaną centroidem $p_j \subset \mathbb{R}$. Jak zostało wspomniane na początku tego rozdziału, w algorytmie C-means zastosowana jest miękka klasteryzacja. Każdy element danych ma przypisywany wektor U_i przynależności do grupy (wzór 2.40).

$$U_i = (u_{i1}, u_{i2}, u_{i3}, \dots, u_{ic}) \quad (2.40)$$

, gdzie u_{i1} oznacza stopień przynależności elementu x_i do grupy 1. Analogicznie u_{i2} oznacza stopień przynależności elementu x_i do grupy 2.

W pierwszym kroku zbiór centroidów P jest inicjalizowany losowo (wzór 2.41).

$$P^0 = (p_1^0, p_2^0, p_3^0, \dots, p_c^0) \quad (2.41)$$

W k -tym kroku algorytmu wyliczona jest macierz funkcji przynależności $U^k = u_{ij}^k$ (wzór 2.42).

$$u_{ij}^k = \frac{1}{\sum_{k=1}^c \left(\frac{\|x_i - p_j^k\|}{\|x_i - p_k^k\|} \right)^{\frac{2}{m-1}}} \quad (2.42)$$

Wyrażenie $\|x_i - p_j\|$ oznacza odległość Euklidesową pomiędzy elementem x_i a centroidem p_j . Parametr „ m ” jest nazywany współczynnikiem rozmycia. Współczynnik ten może być w zakresie od 1 do nieskończoności, jednak w większości przypadków jest równy 2.

W kroku $(k+1)^{th}$ centroid $p_j^{(k+1)}$ jest uaktualniany według wzoru 2.43.

$$p_j^{(k+1)} = \frac{\sum_{i=1}^n u_{ij}^{(k+1)m} x_j}{\sum_{i=1}^n u_{ij}^{(k+1)m}} \quad (2.43)$$

Algorytm w kolejnych iteracjach minimalizuje kryterium $J(U, P)$ podane wzorem 2.44:

$$J(U, P) = \sum_{i=1}^n \sum_{j=1}^c u_{ij}^m \|x_i - p_j\|^2 \quad (2.44)$$

Iteracje kończą się, gdy zostanie osiągnięty warunek opisany wzorem 2.45

$$\|J^{(k+1)}(U, P) - J^{(k)}(U, P)\| < \epsilon \quad (2.45)$$

, gdzie $\epsilon > 0$. Parametr ϵ jest parametrem ustawianym przed uruchomieniem klasteryzacji. W niektórych implementacjach istnieje możliwość zakończenia działania algorytmu po określonej liczbie iteracji, jeśli wcześniej nie zostanie osiągnięte kryterium ze wzoru 2.45.

Po zakończeniu działania wyżej opisanego algorytmu zostaje wyliczony wektor przynależności U (wzór 2.40). Suma wektora przynależności U_i , dla elementu x_i jest opisana Wzorem 2.46

$$\sum_{j=0}^{j=c} u_{ij} = 1 \quad (2.46)$$

, gdzie c oznacza liczbę klastrów. Element x_i będzie należał do klastra k , jeśli u_{ik} ma największą wartość w wektorze U_i .

W tym akapicie zostanie przedstawiony algorytm trenowania za pomocą Fuzzy C-means. Z każdego zdjęcia „i” otrzymywane są dane dotyczące rzeczywistego wieku A_i oraz parametr wskaźnika zmarszczek F_i . W algorytmie Fuzzy C-means są grupowane dane zawierające wartości wskaźnik zmarszczek F_i . Jak wiadomo z powyższego opisu algorytmu Fuzzy C-means, każdy element (w tym przypadku F_i) ma określony stopień przynależności do każdego klastra. Dany element F_i będzie należał do klastra o największym stopniu przynależności. Każde zdjęcie jest grupowane według wyżej opisanego algorytmu.

Każdy klaster ma określony centroid j , który posiada parametr P_{fj} oraz dodatkowy parametr - średnią wartość wieku P_{aj} . P_{fj} oznacza wartość wrin-

kle feature dla danego centroida. P_{aj} jest wyznaczany ze wzoru 2.47.

$$P_{aj} = \frac{\sum A_c}{N_j} \quad (2.47)$$

, gdzie A_c to rzeczywisty wiek osoby z obrazu c , który należy do klastru j . Natomiast N_j to liczba zdjęć zaklasyfikowanych do klastru j .

W powyższym akapicie został opisany algorytm trenowania, który generuje n centroidów, reprezentujących każdą grupę. Natomiast osobnym etapem jest szacowanie wieku. Należy podkreślić, że zdjęcia do testowania algorytmu szacowania wieku pochodzą z innej bazy obrazów niż obrazy wykorzystane w treningu. Ma to na celu eliminację błędów w testowaniu algorytmu. W pierwszej fazie działanie algorytmu jest dokładnie takie same jak w sekcjach od 2.1 do 2.4: Algorytm szacowania wieku w pierwszej kolejności dokonuje detekcji twarzy, oczu, ust na danym obrazie O_i . Jeśli powyższe elementy zostały zidentyfikowane, wyznaczane są strefy zmarszczkowe, a następnie zostaje wyliczony parametr wskaźnik zmarszczek F_i [24].

Dla parametru F_i zostaje wyznaczony wektor przynależności do grupy według wzoru 2.40. Przy założeniu dla wektora przynależności zgodnym ze wzorem 2.46 szacowany wiek PA wynosi (wzór 2.48).

$$PA = \sum_{j=1}^c (u_{ij} * P_{aj}) \quad (2.48)$$

, gdzie u_{ij} oznacza przynależność i -tego zdjęcia do j -tego klastra, c oznacza liczbę klastrów, natomiast P_{aj} jest średnim wiekiem dla j -tego centroida.

Rozdział 3

Modyfikacje metody bazowej

W pracy została odtworzona oryginalna praca autorów, która będzie dalej nazywana metodą bazową. W celu poprawienia wyników metody bazowej wprowadzono kilka modyfikacji, a w kolejnym kroku wyniki zostały porównane z pozostałymi metodami.

Parametrem określającym jakość metody bazowej oraz metod zmodyfikowanych jest średni błąd bezwzględny, który został określony we wzorze 3.1.

$$MAE = \frac{\sum_{i=1}^n |R_i - P_i|}{n} \quad (3.1)$$

, gdzie R_i oznacza wartość rzeczywistą wieku dla i -tego zdjęcia, n oznacza liczbę zdjęć testowych. Natomiast P_i oznacza wartość szacowaną wieku.

3.1 Odjęcie wybranej strefy

Pierwsza modyfikacja polegała na odjęciu jednej wybranej strefy. Detektor Canny oprócz zmarszczek wykrywa także włosy. Podczas przeglądania wielu zdjęć zauważono, że w obrębie strefy zmarszczek nr 2 (obraz 2.15) wykrywane są części brwi oprócz samych zmarszczek. Generuje to błąd, dlatego wyżej wymienionej strefy nie uwzględniono w obliczeniach. W sekcji 3.1.1 porównano różnice w algorytmie przed opisaną wyżej modyfikacją i po niej.

3.1.1 Zmiana algorytmu względem metody bazowej

Przed modyfikacją metody bazowej parametr wskaźnika zmarszczek był obliczany według wzoru 2.38, który jest umieszczony w sekcji 2.4.

Po modyfikacji wskaźnik zmarszczek oblicza się według wzoru 3.2.

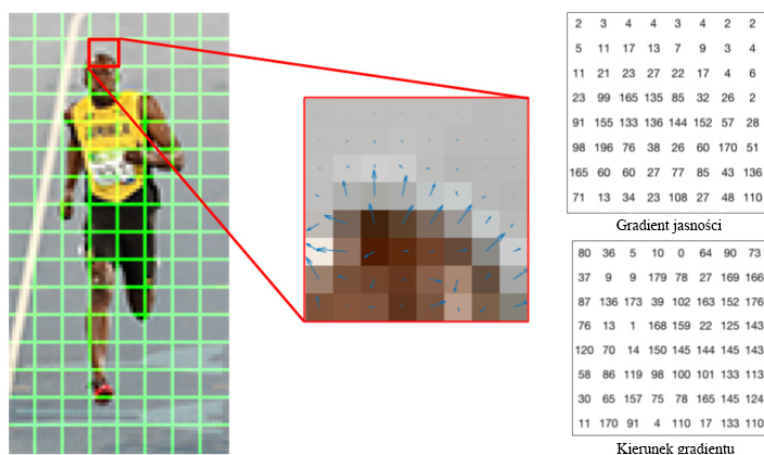
$$WZ = W_{s1} + W_{s3} + W_{s4} + W_{s5} + W_{s6} \quad (3.2)$$

Kolejną modyfikacją było zastosowanie metody HOG - Histograms of Oriented Gradients, która została opisana w sekcji 3.2.

3.2 Zastosowanie metody HOG

Metoda HOG (Histogram of Oriented Gradients) jest deskryptorem cech z obrazu. Deskryptor cech wyodrębnia z obrazu pewne cechy, do których należą między innymi kształty, kolory czy tekstury. W metodzie bazowej rolę deskryptora tego rodzaju spełnia detektor krawędzi Canny (sekcja 2.3), który wykrywa krawędzie, identyfikowane jako zmarszczki. Z kolei Histogram of Oriented Gradients jest techniką, która liczy wystąpienia kierunków gradientów jasności. Liczenie jest dokonywane tylko w pewnych obszarach obrazów. Metoda HOG została wymyślona i opisana w 1982 przez Roberta K. McConella. McConell pracował w tamtym czasie dla firmy Wayland Research Inc., a opis jego metody został zawarty w patencie „Method of and apparatus for pattern recognition” [19]. Jednak jego metoda została po raz pierwszy zaimplementowana dopiero w 2005 roku przez Navneeta Dalala i Billa Triggsa [7] z francuskiego instytutu zajmującego się badaniami w zakresie informatyki i automatyki (INRIA - Institut National de Recherche en Informatique et en Automatique). Metoda McConella została wtedy zastosowana do detekcji pieszych na zdjęciach. Później metoda została rozszerzona o wykrywanie ludzi w filmach wideo, ponadto później stosowano ją także do wykrywania zwierząt oraz pojazdów na zdjęciach.

Metoda Histogram of Oriented Gradients opiera się na założeniu, że wygląd i kształt obiektów na obrazie może zostać opisany przez gradient jasności



Rysunek 3.1: Gradient jasności identyfikujący granicę pomiędzy głową a tłem [18].

oraz jego kierunek. Jest to dobrze widoczne na rysunku 3.1

Na granicy pomiędzy tłem, a głową sportowca widoczne są duże wartości gradientu jasności. W ten sposób zostaje zidentyfikowana krawędź głowy.

Działanie algorytmu można pokrótce opisać w następujący sposób. Obraz jest dzielony na małe obszary zwane komórkami, które zwykle mają wymiar kilka na kilka pikseli. Dla każdego piksela w komórce tworzony jest histogram kierunków gradientu. Następnie histogramy są łączone w jeden wspólny deskryptor. Dla zwiększenia dokładności lokalne histogramy normalizowane są pod względem kontrastu. Realizowane jest to przez pomiar jasności obszaru zwanego blokiem, który składa się z kilku komórek. Normalizacja zapewnia zmniejszenia niepożądanego efektu generowanego przez różnice w oświetleniu różnych obszarów zdjęcia. Wspomniana sytuacja występuje na przykład, gdy zdjęcie wykonywane jest w nieprawidłowych warunkach oświetleniowych (rysunek 2.3).


W poniższym akapicie zostanie przedstawiony dokładny opis metody Histogram of Oriented Gradients. W pierwszej fazie obraz powinien zostać przeskalowany, tak aby jego wymiary były podzielne przez rozmiar pojedynczej komórki. (rysunek 3.2).

Warto wspomnieć, że w wielu metodach generujących deskryptory pierwszą fazą jest korekcja luminancji. Jednak ten krok może zostać pominięty,



Rysunek 3.2: Komórki o rozmiarze 8x8 pikseli na zdjęciu [18].

gdyż w późniejszym kroku stosowana jest normalizacja, która dokonuje korekcji luminancji cieni oraz światła. W kolejnej fazie muszą zostać wyznaczone gradienty jasności. Wyznaczenie gradientów jasności zostało szczegółowo opisane w sekcji 2.3.2. W kolejnej fazie zostają wyznaczone histogramy gradientów dla każdej komórki. Na rysunku 3.1 został przedstawiony wynik działania tego kroku. Zostają wygenerowane dwie macierze. Pierwsza zawiera informację o gradiencie jasności każdego piksela komórki, natomiast druga - informację o kierunku każdego gradientu. Wartości kierunku gradientu wyrażone są w stopniach. W metodzie Histogram of Oriented Gradients zastosowano kierunki gradientu bez znaku. Oznacza to, że zakres kierunków mieści się w granicach od 0° do 180° . Kierunek gradientu ze znakiem posiadałby zakres od 0° do 180° oraz jego ujemny odpowiednik (od -179° do -1°). Użycie kierunku gradientu bez znaku jest uzasadnione tym, że wartość kierunku o takiej samej wartości, lecz różnych znakach reprezentuje gradient o tym samym kierunku, lecz różnych zwrotach. Dla detekcji kształtów krawędzi czy kształtów istotny jest kierunek, a nie zwrot. Na podstawie kierunku gradientu oraz wartości gradientu jasności zostaje wygenerowany histogram gradientów. W parametrze wejściowym algorytmu HOG ustawiana jest ilość



Rysunek 3.3: Komórki o rozmiarze 8x8 pikseli na zdjęciu [18].

komórek histogramu. Najczęściej stosuje się 9 komórek. Każda komórka histogramu odpowiada pewnemu zakresowi kąta kierunku gradientu. Przykładowo dla histogramu o szerokości 9 komórek każda komórka odpowiada następującym kątom: 0° , 20° , 40° , \dots , 160° . Na rysunku 3.3 przedstawiono sposób przypisywania wartości do komórek histogramu. Piksel zaznaczony na niebiesko posiada gradient o wartości 2 oraz kierunek o kącie 80° . Wartość gradientu zostaje dodana do komórki histogramu reprezentującego kąt 80° . Piksel zaznaczony na czerwono posiada gradient o wartości 4 oraz kierunek o kącie 10° . Wartość gradientu równa 4 zostaje rozdzielona na dwie proporcjonalne wartości: 2 oraz 2, które są dodawane do komórek reprezentujących kąt 0° oraz 20° . Proporcje zależą od kąta gradientu i od kątów w komórkach histogramu. Tak jak w powyższym przypadku, jeśli wartość kąta wynosi 10° , wartości gradientu są przydzielane do komórek reprezentujących dwa kąty (w tym przypadku przedziały reprezentujące kąt od 0° do 20°). W związku z tym, że powyższy kąt wynosi 10° , wartości dla komórek histogramu są obliczane według wzoru 3.3 oraz wzoru 3.4:

$$X_a = \frac{A_x - A_a}{A_b - A_a} * G_x \quad (3.3)$$

, gdzie X_a oznacza wartość przydzielaną do komórki reprezentującej mniejszy kąt (tak jak 0° dla powyższego przykładu), A_x oznacza wartość kąta gradientu dla danego piksela (tak jak 10° dla powyższego przykładu), A_a oznacza kąt dla komórki reprezentującej mniejszy kąt (tak jak 0° dla powyższego przykładu), A_b oznacza kąt dla komórki reprezentującej większy kąt (tak jak 20° dla powyższego przykładu), a G_x oznacza wartość gradientu dla danego piksela (tak jak 4 dla powyższego przykładu).

$$X_b = \frac{A_b - A_x}{A_b - A_a} * G_x \quad (3.4)$$

, gdzie X_b oznacza wartość przydzieloną dla kąta o większej wartości (tak jak 20° dla powyższego przykładu).

Reszta zmiennych odpowiada zmiennym we wzorze 3.3. W przypadku, gdy kąt kierunku gradientu jest większy od 160° to wartość danego gradientu jest przydzielana proporcjonalnie do komórki 160° oraz 0° zgodnie ze wzorem 3.4. Jednak wartość komórki 0° zostaje zastąpiona kątem 180° , a wyliczona wartość zostaje przydzielona do komórki reprezentującej kąt 0° . Powyższa procedura jest powtarzana, a kolejne wartości gradientów są dodawane do aktualnych wartości przechowywanych w komórkach histogramu. Końcowy efekt tej fazy dostarcza histogram reprezentujący komórkę. Wartości histogramu dla danej komórki reprezentują część wektora deskryptora. Deskryptor składa się z n histogramów, gdzie n oznacza liczbę komórek w danym obrazie [7].

Kolejnym krokiem jest normalizacja bloków. Blok składa się z komórek i zazwyczaj ma wymiary 2×2 komórki. Gradienty jasności są czułe na zmiany oświetlenia na obrazie. Celem tej fazy algorytmu jest normalizacja oświetlenia, aby uodpornić deskryptor na zmiany oświetlenia. Istnieje wiele sposobów normalizacji. Zostanie tutaj opisana normalizacja za pomocą parametru

L2-norm. Najpierw zostaje wyliczona wartość L2-norm. L2 jest wartością normalizującą wektor v , który reprezentuje wartości deskryptora dla danego bloku. Wspomniany wektor składa się z wartości zawartych w komórkach histogramu. Jak wiadomo z przedstawionego wyżej opisu, każdy histogram opisuje jedną komórkę, a blok zawiera n komórek. Przyjmując, że histogram reprezentujący komórkę posiada 9 wartości oraz rozmiar bloku wynosi 2×2 komórki, można wyznaczyć długość wektora v . Blok ma 2×2 komórki, więc zawiera w sobie 4 komórki. Każda komórka ma 9 wartości histogramu, zatem wektor v będzie miał długość 9×4 , czyli 36. L2-norm dla wektora v jest obliczane według wzoru 3.5

$$\|v\|_2 = \sqrt{\sum_{i=0}^n v(i)^2} \quad (3.5)$$

, gdzie $\|v\|_2$ jest wartością L2-norm, natomiast $v(i)$ jest i -tym elementem wektora v . Normalizacja jest realizowana przy zastosowaniu Wzoru

$$v = \frac{v}{\|v\|_2} \quad (3.6)$$

, gdzie $\|v\|_2$ jest wartością L2-norm dla wektora v . Działanie zgodne ze wzorem 3.6 oznacza, że każdy element wektora v jest dzielony przez wartość $\|v\|_2$. Powyższy proces powtarza się dla wszystkich bloków. W wyniku działania algorytmu Histograms of Oriented Gradients wygenerowany zostaje deskryptor, czyli wektor reprezentujący wartości histogramów wszystkich komórek w obrazie.

Deskryptor HOG posiada kluczową zaletę w stosunku do innych metod ekstrakcji cech. Jest nią odporność metody Histogram of Oriented Gradients na działanie przekształceń geometrycznych dzięki temu, że dokonuje działań na komórkach lokalnych. Przekształcenia geometryczne to działania, które przekształcają figury z jednej przestrzeni geometrycznej w drugą. Przykładem przestrzeni geometrycznej są przestrzeń euklidesowa czy przestrzeń rzutowa. Ponadto działania na komórkach lokalnych pozwalają zmniejszyć efekt powstający przy ruchu pieszego. Z uwagi na powyższe zalety ta metoda na-

daje się do detekcji ludzi na obrazach.

W niniejszej pracy opisywana metoda posłużyła do wykrywania krawędzi, które informują o zmarszczkach. Dokładny sposób jej zaimplementowania w pracy opisuje sekcja 3.2.1

3.2.1 HOG - Zastosowanie w projekcie

W poprzedniej sekcji 3.2 został dokładnie opisany algorytm HOG, w wyniku którego generowany jest deskryptor dla danego obrazu.

Omówiony wyżej deskryptor posłużył do wykrycia ilości zmarszczek w strefach zmarszczkowych. Jak wiadomo z opisu w sekcji 3.2 metoda HOG pozwala na wykrywanie krawędzi w danym obrazie. Jeśli w danym obszarze jest dużo krawędzi, to w wektorze deskryptora będzie pewna ilość elementów tego wektora o znacznej wartości. Wyżej opisywane, charakterystyczne elementy wektora będą identyfikowały krawędzie w obrazie. Jak wiadomo z sekcji 2.4 krawędzie mogą zostać zinterpretowane jako zmarszczki. W związku z powyższym zmodyfikowano sposób obliczenia wrinkle feature dla obrazu twarzy opierając się o deskryptor wygenerowany przez algorytm HOG.

W bibliotece OpenCv zaimplementowany jest algorytm HOG, który na podstawie całego obrazu lub jego pewnego obszaru generuje wektor reprezentujący deskryptor. Biblioteka umożliwia ustawienie różnych parametrów HOG-a. Do tych parametrów zalicza się:

- rozmiar komórki w pikselach
- rozmiar bloku w pikselach
- liczba komórek w histogramie
- rozmiar okna - wielkość analizowanego obrazu w pikselach

W celu oszacowania ilości zmarszczek dla danego zdjęcia posłużono się następującym algorytmem.

W pierwszej fazie zostały wyznaczone strefy zmarszczkowe nr 1,3,4,5,6. (rysunek 2.15). Następnie dla każdej wyżej wymienionej strefy został wyzna-

czony deskryptor. Dla strefy 1 deskryptor jest opisany zmienną v_1 , dla strefy 3 zmienną v_3 i tak dalej. Wskaźnik zmarszczek jest obliczany ze wzoru 3.7:

$$WF_{HOG} = \|v_1\|_1 + \|v_3\|_1 + \|v_4\|_1 + \|v_5\|_1 + \|v_6\|_1 \quad (3.7)$$

, gdzie $\|v_1\|_1$ jest parametrem L1-norm dla wektora v_1 . Analogicznie $\|v_3\|_1$ jest parametrem L1-norm dla wektora v_3 .

Parametr L1-norm dla danego wektora v jest wyznaczany ze wzoru 3.8:

$$\|v\|_1 = \sum_{i=1}^n |v(i)| \quad (3.8)$$

, gdzie $v(i)$ jest i -tym elementem wektora.

Dla każdego zdjęcia ze zbioru podobnie jak w metodzie bazowej 2.3 wyznaczana jest para danych WF_{HOG} (wzór 3.7) oraz wiek. Następnie wygenerowany zbiór danych jest trenowany za pomocą Fuzzy C-means (sekcja 2.6) - tak samo jak w metodzie bazowej. Wiek szacowany jest dokładnie tak samo jak w metodzie bazowej. Kolejna modyfikacja metody bazowej została opisana w sekcji 3.3

3.3 Metoda HOG oraz algorytm KNN

3.3.1 Zastosowanie w projekcie

Kolejna modyfikacja polegała na zmianie sposobu wyznaczania wskaźnika zmarszczek. W sekcji 3.2.1 przedstawiono sposób wyznaczania wskaźnika zmarszczek, który polegał na sumowaniu deskryptorów z poszczególnych stref (wzór 3.7). W celu poprawy wyników uwzględniono deskryptory ze wszystkich stref. Dla każdego zdjęcia ze zbioru wyznaczana jest para danych - wiek oraz wektor. $\overrightarrow{v_{KNN}}$ składający się z elementów według wzoru 3.9

$$\overrightarrow{v_{KNN}} = (\|v_1\|_1, \|v_3\|_1, \|v_4\|_1, \|v_5\|_1, \|v_6\|_1) \quad (3.9)$$

W wyniku treningu zbioru zdjęć zostaje wygenerowany zbiór zawierający wyżej wymienioną parę danych. Następnie w celu oszacowania wieku zostaje wykorzystany algorytm KNN, który został opisany w sekcji 3.3.2.

3.3.2 Grupowanie KNN

Algorytm KNN (ang. k-Nearest Neighbor) to algorytm regresji nieparametrycznej używany w statystyce do prognozowania wartości pewnej zmiennej losowej. Został stworzony w roku 1970. KNN tłumaczone jest na język polski jako algorytm k- najbliższych sąsiadów. Algorytm KNN na wejściu otrzymuje zbiór danych nazywany zbiorem uczącym. Zbiór uczący zawiera dane zwane obserwacjami. Wspomniane obserwacje są parą danych (wzór 3.10).

$$O_i = (K_i, V_i) \quad (3.10)$$

, gdzie O_i jest daną obserwacją, K_i - klasą, natomiast V_i - wektorem zmiennych objaśniających. Przykładowo taką jedną obserwację może tworzyć klasa określająca wiek danej osoby, a wektorem może być ilość zmarszczek.

Natomiast zbiór uczący będzie posiadał n powyższych obserwacji, na podstawie których można wywnioskować, do jakiej klasy będzie zaliczana obserwacja testowa. Obserwacja testowa to obserwacja, która posiada wektor zmiennych objaśniających i może zostać zaliczona do danej klasy za pomocą algorytmu KNN. Wracając do powyższego przykładu, obserwacja testowa będzie zawierała tylko wektor określający ilość zmarszczek. Natomiast algorytm KNN przypisze tę obserwację do klasy (wieku). Przypisywanie do danej klasy jest realizowane przez ocenę podobieństwa obserwacji testowej do zbioru uczącego. Ocena podobieństwa jest realizowana poprzez obliczanie odległości pomiędzy wektorami zmiennych objaśniających [11].

Przykładowymi miarami odległości są:

- miara Euklidesowa
- miara Manhattan

- miara Czebyszewa
- miara Minkowskiego

Odległość pomiędzy dwoma wektorami w mierze Euklidesowej jest opisana wzorem 3.11

$$D(\vec{n}, \vec{m}) = \sum_{i=1}^c (n(i) - m(i))^2 \quad (3.11)$$

, gdzie $D(\vec{n}, \vec{m})$ oznacza odległość pomiędzy dwoma wektorami w mierze Euklidesowej. Natomiast $n(i)$ oznacza i -ty element wektora \vec{n} , $m(i)$ - i -ty element wektora \vec{m} , a c jest długością wektora \vec{n} oraz \vec{m} .

W mierze Manhattan odległość pomiędzy dwoma wektorami jest opisana Wzorem 3.12

$$D(\vec{n}, \vec{m}) = \sum_{i=1}^c |n(i) - m(i)| \quad (3.12)$$

, gdzie $D(\vec{n}, \vec{m})$ oznacza odległość pomiędzy dwoma wektorami w mierze Euklidesowej. Z kolei $n(i)$ oznacza i -ty element wektora \vec{n} , $m(i)$ - i -ty element wektora \vec{m} , a c jest długością wektora \vec{n} oraz \vec{m} .

Miara Czebyszewa opisuje odległość pomiędzy dwoma wektorami zgodnie z Wzorem 3.12

$$D(\vec{n}, \vec{m}) = \max_{i=1:n} (|n(i) - m(i)|) \quad (3.13)$$

, gdzie $D(\vec{n}, \vec{m})$ oznacza odległość pomiędzy dwoma wektorami w mierze Euklidesowej. $n(i)$ oznacza i -ty element wektora \vec{n} , $m(i)$ - i -ty element wektora \vec{m} , natomiast c jest długością wektora \vec{n} oraz \vec{m} .

Odległość pomiędzy dwoma wektorami w mierze Minkowskiego jest opisana wzorem 3.14

$$D(\vec{n}, \vec{m}) = \left(\sum_{i=1}^c |n(i) - m(i)|^p \right)^{\frac{1}{p}} \quad (3.14)$$

Zmienne są dokładnie takie same jak we wzorze 3.11. , gdzie $D(\vec{n}, \vec{m})$ ozna-

cza odległość pomiędzy dwoma wektorami w mierze Euklidesowej. Natomiast $n(i)$ oznacza i -ty element wektora \vec{n} , $m(i)$ - i -ty element wektora \vec{m} , c jest długością wektora \vec{n} oraz \vec{m} . Parametr p nazywany jest dystansem Minkowskiego.

W celu zmniejszenia błędów klasyfikacji w algorytmie KNN może zostać zastosowana standaryzacja lub normalizacja danych. Zastosowanie wyżej wymienionych technik pozwala na zmniejszenie dominacji wartości wektorów, których wartość jest znacznie większa lub mniejsza od ogólnej średniej. Przykładowo, przy założeniu, że wartością objaśniającą byłaby długość wyrażona w metrach i średnia tej wartości w całym zbiorze uczącym wyniosłaby 1 m, to dominującą wartością w tym zbiorze byłaby np. wartość 100 metrów.

Standaryzacja ma na celu obliczenie nowych wartości elementów wektorów ze zbioru uczącego. Standaryzacja jest zrealizowana poprzez wzór 3.15:

$$v_u(i) = \frac{v_u(i) - m(v_u)}{\sigma(v_u)} \quad (3.15)$$


, gdzie v_u jest wektorem zmiennej objaśniającej ze zbioru uczącego, u - indeksem wektora zmiennej objaśniającej, i jest elementem wektora v_u , $m(v_u)$ jest średnią elementów wektora v_u . Natomiast $\sigma(v_u)$ jest odchyleniem standardowym elementów wektora v_u .

Normalizacja generuje wartości elementów wektorów ze zbioru uczącego, tak aby powyższe wartości mieściły się w przedziale od 0 do 1 (Wzór 3.16).

$$v_u(i) = \frac{v_u(i) - \min(v_u)}{\max(v_u) - \min(v_u)} \quad (3.16)$$

, gdzie v_u jest wektorem zmiennej objaśniającej ze zbioru uczącego, u - indeksem wektora zmiennej objaśniającej, i jest elementem wektora v_u , $\max(v_u)$ oznacza maksymalną wartość spośród elementów wektora v_u . Natomiast $\min(v_u)$ minimalną wartość spośród elementów wektora v_u .

Powyżej zostały objaśnione terminy i idea algorytmu KNN. W kolejnym akapicie zostanie przedstawiony sam algorytm. Tak jak zostało opisane wy-



Rysunek 3.4: Przykład klasyfikacji KNN [22].

zej - algorytm otrzymuje zbiór uczący zawierający obserwację. Następnie zbiór uczący może być standaryzowany lub normalizowany. Ponadto algorytm otrzymuje parametr k . W celu wywnioskowania, do której klasy należy obserwacja testowa zawierająca wektor V_i , szukanych jest k najbliższych wektorów (wektorów sąsiadów) ze zbioru uczącego (według kryterium odległości). Obserwacja testowa zostaje przydzielona do klasy, która najczęściej występowała wśród k sąsiednich obserwacji [11]. Problem klasyfikacji algorytmem KNN jest pokazany na rysunku 3.4

Na rysunku 3.4 wyróżnione są wektory ze zbioru uczącego należące do klasy „A” oraz klasy „B”. Ponadto na środku rysunku 3.4 znajduje się wektor, który ma zostać sklasyfikowany do jednej z wyżej wymienionych klas. Dla parametru „ k ” równego 3 wektor testowy zostanie przypisany do klasy „B”, gdyż z trzech najbliższych wektorów dwa należą do klasy „B”. W przypadku, gdy parametr „ k ” będzie równy 7 wektor testowy zostanie przypisany do klasy „A”. Spośród siedmiu najbliższych sąsiadów, cztery wektory należą do klasy „A”, natomiast trzy - do klasy „B”.

Wybór parametru k jest zależny od rodzaju danych. Im większa wartość

k , tym mniejszy wpływ na proces klasyfikacji ma szum, który określa błędne dane w zbiorze uczącym. Istnieją metody dobierające optymalną wartość k dla danego zbioru uczącego. Do jednej z nich należy optymalizacja hiperparametryczna.

Na końcu sekcji 3.3.1 został przedstawiony sposób, w jaki generowany jest zbiór uczący. Szacowanie wieku metodą KNN w pierwszym kroku polega na stworzeniu wektora, który został opisany wzorem 3.9. Następnym krokiem jest przydzielenie danego wektora do klasy (wieku).

W sekcji 4 zostaną przybliżone metody przeprowadzanie badań oraz ich wyniki.

Rozdział 4

Badania

W niniejszym rozdziale zostaną przedstawione badania metody bazowej oraz jej modyfikacji. Sekcja 4.1 prezentuje środowisko pracy, a dokładniej mówiąc wszystkie niezbędne narzędzia i akcesoria, które pozwoliły skutecznie przeprowadzić badania. W sekcji 4.2 przedstawiono wpływ rozmiaru danego obrazu na wyniki badań. Sekcja 4.3 ukazuje efekty wykrywania zmarszczek przez detektor Canny. W kolejnej sekcji

4.1 Środowisko badań

W celu przeprowadzenia badań do niniejszej pracy magisterskiej wymagane było stworzenie programu, który wykrywa twarz oraz wyodrębnia cechy z twarzy. Wyżej wymieniony program został napisany w języku Java. Biblioteka, która pomogła wyodrębniać cechy z obrazu, to OpenCv. Sama ta biblioteka jest stworzona w języku C++, jednak istnieją jej modyfikacje, które zostały napisane w innych językach. Najczęściej spotykane są modyfikacje stworzone w języku Java oraz Python. Ponadto w Javie generowano dane dla metody bazowej oraz wszystkich jej modyfikacji. Dodatkowo to w tym języku zrealizowano szacowanie wieku we wszystkich metodach, z pominięciem metody, która stosuje algorytm KNN (sekcja 3.3).

Grupowanie danych algorytmem Fuzzy C-means zostało zrealizowane za pomocą programu Matlab. Również szacowanie wieku dla metody stosującej

algorytm KNN przeprowadzono za pomocą wyżej wymienionego programu.

Dane z treningu były generowane do plików CSV oraz JSON. Ponadto większość kluczowych operacji była logowana do plików. Do tego celu posłużyła popularna biblioteka Log4j. Generacja plików JSON była zrealizowana przez bibliotekę GSON z pakietu `com.google.code.gson`, natomiast do generacji plików CSV nie została wykorzystana zewnętrzna biblioteka.

4.2 Rozmiar obrazu

Wymiary obrazów z bazy UTKface mieszczą się w zakresie od 186 pikseli do 1300. Natomiast obszar wykrytej twarzy miał rozmiar od 165 do 450 pikseli. Sprawdzone wskaźnik zmarszczek wygenerowany za pomocą detektora Canny oraz HOG dla jednego zdjęcia ze zbioru treningowego w kilku rozmiarach. Dla detektora Canny zmieniano wartość powiększenia zdjęcia od 0,8 do 1,20. Wartość parametru wrinkle feature nie uległa zmianie. Natomiast ponad i poniżej powyższego zakresu powiększenia detektor nie mógł wykryć i prawidłowo zlokalizować oczu.

Dla detektora opartego na algorytmie HOG wskaźnik zmarszczek był następujący:

- powiększenie 0,8: 11.944
- powiększenie 0,9: 11.813538
- powiększenie 1,0: 12.01074
- powiększenie 1,1: 11.117805
- powiększenie 1,2: 11.125154

Dla detektora opartego na algorytmie HOG wraz z klasyfikatorem KNN wskaźnik zmarszczek przyjął poniższe wartości

- powiększenie 0,8: [2.455685, 2.4238224, 2.3258488, 2.5089853, 2.22999]
- powiększenie 0,9: [2.3424015, 2.183178, 2.402356, 2.6400175, 2.245584]

- powiększenie 1,0: [2.4636364, 2.3633847, 2.4149206, 2.171613, 2.5971856]
- powiększenie 1,1: [2.3787472, 2.184542, 2.335689, 1.9784055, 2.2404206]
- powiększenie 1,2: [2.3283577, 2.1853786, 2.3087728, 2.0892627, 2.2133815]

Na podstawie wyników można wywnioskować, że wskaźnik zmarszczek nie zwiększa się przy zmianie powiększenia zdjęcia dla metody opartej na detektorze Canny. Natomiast zmiany były zauważalne zarówno dla metody korzystającej z algorytmu HOG, jak również HOG z klasyfikatorem KNN.

Okazało się, że w pewnych warunkach detekcja metodą HOG i KNN nie oblicza współczynnika zmarszczek dla strefy 3 i 6. Wynikało to z rozmiaru obrazu oraz parametrów HOG. Okazało się również, że gdy szerokość obszaru zmarszczek jest mniejsza od szerokości pojedynczego bloku lub długość tego obszaru jest mniejsza od długości pojedynczego bloku, to długość deskryptora wynosi 0. Zgodnie z powyższym suma deskryptora dla opisywanego obszaru jest równa 0. Tracone są w ten sposób informacje o zmarszczkach.

Problem został zauważony dla obrazów o wymiarach 165 x 213 pikseli i następujących parametrów HOG:

- blok 18 x 18 pikseli
- komórka 9 x 9 pikseli

Analogiczna sytuacja może nastąpić, gdy długość bloku jest większa od długości obszaru zmarszczek.

Można przyjąć pewne minimalne wymiary obrazu twarzy, zakładając, że maksymalna długość i szerokość bloku wyniesie 18 pikseli. W związku z powyższym szerokość i/lub długość strefy zmarszczkowej nie może być mniejsza od 18 pikseli. Jak już wcześniej zostało wspomniane, najbardziej wrażliwe na brak generacji deskryptora są strefy 3 i 6. W pierwszym kroku należało wydedukować, jaki obszar zajmuje w przybliżeniu jedna strefa 3 lub 6 w stosunku do obszaru twarzy. Na podstawie logów aplikacji wygenerowanych w trakcie detekcji stref dla zdjęć z bazy treningowej wyznaczono średni obszar jednej strefy 3 lub 6. Następnie porównano rozmiar obszaru twarzy w pikselach z

rozmiarem wyznaczonej strefy 3 lub 6. Porównanie wyżej wymienionych wymiarów przeprowadzono dla kilkudziesięciu zdjęć. Na podstawie uzyskanych danych po prostych obliczeniach stwierdzono, że jedna strefa 3 lub 6 zajmuje od 8% do 15% na szerokość obszaru twarzy oraz od 15% do 25% na długość obszaru twarzy. W związku z powyższym minimalna szerokość bloku wyniosła 8% szerokości obszaru twarzy, natomiast minimalna długość wyniosła 15%. Najmniejsza możliwa szerokość obszaru twarzy w pikselach względem szerokości bloku jest opisana wzorem 4.1.

$$T_{wmin} = \frac{1}{B_{wrmin}} * B_w \quad (4.1)$$

, gdzie B_{wrmin} oznacza minimalną szerokość bloku w stosunku do szerokości obszaru twarzy (w szerokość bloku w pikselach, natomiast T_w oznacza minimalną szerokość obszaru twarzy.

Analogicznie minimalna długość obszaru twarzy względem długości bloku jest opisana wzorem 4.2.

$$T_{hmin} = \frac{1}{B_{hrmin}} * B_h \quad (4.2)$$

, gdzie B_{hrmin} oznacza minimalną długość bloku w stosunku do długości obszaru twarzy (w %), natomiast B_h oznacza długość bloku w pikselach, a T_{hmin} określa minimalną długość obszaru twarzy.

Jak wynika z powyższego wzoru 4.1, minimalna szerokość obszaru twarzy powinna być co najmniej 12,5 razy większa od szerokości bloku. Natomiast według wzoru 4.2 długość obszaru zawierającego twarz powinna być co najmniej 6,7 razy większa od długości bloku.

W drugim kroku należało odnaleźć obszar, jaki zajmuje twarz w stosunku do wymiarów obrazu. W tym celu porównano zdjęcia z bazy treningowej pod kątem wyżej wymienionych obszarów. Podobnie jak w pierwszym kroku, przeprowadzono porównanie dla kilkudziesięciu zdjęć. Okazało się, że minimalny obszar zajęty przez twarz wyniósł 75 % na szerokość całego obrazu oraz 80 % na jego długość. W świetle powyższych danych należy stwierdzić, że obszar twarzy jest 1,33 razy węższy oraz 1,25 razy krótszy od obszaru

całego obrazu.

Zgodnie z wynikami pierwszej fazy badań, obszar twarzy powinien być 12,5 razy szerszy od szerokości bloku, a jednocześnie 1,33 razy węższy od samego obrazu, więc szerokość obrazu powinna być $12,5 * 1,33$, czyli w przybliżeniu 16,7 razy większa od szerokości bloku.

Obliczenia dla minimalnej długości obrazu są analogiczne do powyższych. Obszar twarzy powinien być 6,7 razy dłuższy od długości bloku, a jednocześnie 1,25 razy krótszy od długości obrazu. W związku z powyższym długość obrazu powinna być $6,7 * 1,25$, czyli w przybliżeniu 8,4 razy większa od długości bloku.

W celu obliczenia parametru wskaźnika zmarszczek dla strefy 3 i 6 obrazy, które miały zbyt mały rozmiar zostały powiększone.

4.3 Wykrywanie zmarszczek przez detektor Canny oraz Histogram of Oriented Gradients


W tej Sekcji zostaną przedstawione typowe problemy napotkane podczas detekcji zmarszczek metodą Canny oraz Histogram of Oriented Gradients. W wielu zdjęciach wystąpiły nieprawidłowe detekcje zmarszczek.

Krawędzie związane tylko ze zmarszczkami są widoczne na obrazie 4.1. Obraz 4.1 będzie dobrym punktem odniesienia do przypadków błędnych detekcji zmarszczek.


Pierwszym przykładem było wykrycie krawędzi związanych z brwiami (obraz 4.2) dla osoby w wieku 17 lat.

Na obrazie można zauważyć, że ilość krawędzi w strefie 2 (obraz (2.15)) jest duża i nie identyfikują one zmarszczek.

Porównano średni współczynnik zmarszczek ze strefy 2 dla osób w wieku 17 lat z ilością krawędzi wykrytych z tej samej strefy na obrazie 4.2. Takie porównanie ma na celu sprawdzenie wpływu nieprawidłowo wykrytych krawędzi na współczynnik zmarszczek.



Rysunek 4.1: Przykład prawidłowej detekcji zmarszczek.
a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek



Rysunek 4.2: Przykład nieprawidłowej detekcji zmarszczek w strefie 2.
a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek

Średni współczynnik zmarszczek w strefie 2 dla osób w wieku 17 lat wyniósł:

- Dla HOG-a 2,43464
- Dla Canny 0,2636


Natomiast dla obrazu 4.2 zawierającego nieprawidłowo wykryte krawędzie ilość zmarszczek wyniosła

- Dla HOG-a 2,97876
- Dla Canny 0,3542

W związku z powyższym różnica pomiędzy średnią ilością zmarszczek w strefie 2 dla wieku 17 lat, a ilością dla obrazu zawierającego nieprawidłowe wykryte krawędzie wynosi :

- Dla HOG-a: $2,97876 - 2,43464$, czyli 0,54412
- Dla Canny: $0,3542 - 0,2636$, czyli 0,0906

Kolejnym problemem okazała się grzywka nachodząca na obszar strefy 1. Na obrazie 4.3 można zauważyć wykryte krawędzie, które identyfikują włosy.



Rysunek 4.3: Przykład nieprawidłowej detekcji zmarszczek w strefie 1.
a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek

Obraz 4.3 przedstawia 51-letnią osobę. Podobnie jak powyżej, przeprowadzono porównanie, które ma na celu sprawdzenie wpływu nieprawidłowo wykrytych krawędzi na współczynnik zmarszczek. Do wspomnianego celu obliczono średni współczynnik zmarszczek ze strefy 2 dla osób w wieku 51 lat, który wyniósł:

- Dla HOG-a: 2,67452
- Dla Canny: 0,3267

Natomiast dla zdjęcia zawierającego nieprawidłowo wykryte krawędzie (obraz 4.3) ilość zmarszczek wyniosła

- Dla HOG-a: 2,95635
- Dla Canny: 0,3953

Różnica pomiędzy średnią ilością zmarszczek w strefie 2 dla wieku równego 51 lat a ilością dla obrazu zawierającego nieprawidłowe wykryte krawędzie wynosi (Obraz 4.3):

- Dla HOG-a: $2,95635 - 2,67452$, czyli 0,28183
- Dla Canny $0,3953 - 0,3267$, czyli 0,0686

4.4 Statystyki z działania programu

W tej sekcji zostaną przedstawione ogólne statystyki z działania programu. Baza UTKface zawiera 23708 zdjęć. Detektor twarzy był w stanie wyznaczyć obszar twarzy dla 14583 obrazów. Jednak spośród 14583 obrazów tylko 2574 brało udział w liczeniu zmarszczek, ponieważ jedynie w tej grupie algorytm poprawnie wykrył obszar nosa oraz oczu, które są niezbędne do dalszych obliczeń. Średnia zajętość RAM-u przez program wyniosła 790 MB. Natomiast maksymalnie program zajmował 1974 MB pamięci RAM.

Na podstawie logów aplikacji sprawdzono czasy przetwarzania poszczególnych części algorytmów.

Średni czas wykrywania twarzy trwał 0,125 sekundy. Maksymalny czas wykrywania wynosił 0,456 sekundy, natomiast najszybciej nastąpiło to w czasie 0,056 sekundy.

Średni czas generacji wrinkle feature obrazu po wykryciu twarzy wyniósł 0,467 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga, generacja trwała 0,465 sekund, dla metody HOG 0,543 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN - 0,543 sekundy.

Maksymalny czas generacji wskaźnika zmarszczek obrazu po wykryciu twarzy wyniósł 0,723 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga było to 0,716 sekundy, dla metody HOG 0,954 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN - 0,956 sekundy.

Minimalny czas generacji wskaźnika zmarszczek obrazu po wykryciu twarzy wyniósł 0,286 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga - 0,274 sekundy, dla metody HOG było to 0,315 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN generacja trwała 0,342 sekundy.

Powyższe dane wykazują, że najszybciej wskaźnik zmarszczek był generowany przez algorytm metody po odjęciu jednej strefy.

Warto porównać również szybkość szacowania wieku na podstawie danego wrinkle feature.

Średni czas szacowania wieku dla danego obrazu wyniósł 0,585 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga ten czas wyniósł 0,583 sekundy, dla metody HOG 0,675 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN 0,678 sekundy.

Maksymalny czas szacowania wieku dla danego obrazu po wykryciu twarzy wyniósł 0,95 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga było to 0,947 sekundy, dla metody HOG 1,152 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN 1,15 sekundy.

Minimalny czas szacowania wieku dla danego obrazu po wykryciu twarzy wyniósł 0,235 sekundy dla metody bazowej. Dla metody, w której została odjęta strefa druga - 0,23 sekundy, dla metody HOG 0,426 sekundy, natomiast dla metody HOG wraz z klasyfikacją KNN czas szacowania wyniósł 0,415

sekundy.

Najszybciej szacował wiek algorytm zawierający odjętą strefę. Warto podkreślić, że szacowanie wieku dla metody HOG wraz z klasyfikacją KNN realizował program realizowany przez skrypt w Matlabie. Pozostałe algorytmy szacowania wieku zostały zrealizowane w programie w języku Java. W związku z powyższym porównanie szybkości działania algorytmu zaimplementowanego w Matlabie do algorytmu zaimplementowanego w Javie może być niedokładne.

4.5 Skuteczność poszczególnych metod szacowania wieku

Do oceny skuteczności szacowania wieku za pomocą poszczególnych metod potrzebna jest baza treningowa oraz testowa. Baza testowa może pochodzić od części danych treningowych. Istnieje kilka metod rozdzielania jednej bazy na bazę treningową oraz testową. Jedną z nich jest rozdzielanie bazy w oparciu o stosunek. Oznacza, to, że uzyskany zbiór treningowy będzie wynosił x procent np. 90%, a zbiór testowy odpowiednio $100\% - x$, np 10%. [16] Drugi ze sposobów to schemat CV-n, zwany również walidacją krzyżową. Zakłada ona, że zbiór danych zostanie podzielony na n równych podzbiorów. Następnie wykonuje się n iteracji. W każdej iteracji jeden podzbiór zostaje zbiorem testowym, natomiast reszta podzbiorów tworzy zbiór treningowy. Każda iteracja daje wynik działania klasyfikatora. W wyniku „ n ” iteracji otrzymuje się uśredniony wynik działania klasyfikatora. [16]

Metoda Leave-One-Out zakłada wykluczenie jednego obiektu, który reprezentuje zbiór testowy. Natomiast reszta obiektów zostaje zakwalifikowana do zbioru treningowego. Po przetestowaniu klasyfikatora powyższym obiektem otrzymuje się wynik skuteczności klasyfikacji. Proces ten jest powtarzany dla wszystkich obiektów. Metoda Leave-One-Out działa dokładnie tak samo jak metoda CV-n dla n równego liczbie obiektów w zbiorze danych. [16]

Przy obliczaniu skuteczności klasyfikacji porównywano parametr MAE wzór 3.1. Dla każdej metody dokonano porównania stu zdjęć, natomiast

każda z nich miała zmieniane parametry algorytmów. W przypadku metody z algorytmem grupowania Fuzzy C-means zmianie podlegały parametry tego właśnie algorytmu. Analogicznie zmieniano właściwości odpowiednich algorytmów dla metody HOG i klasyfikatora KNN.

4.5.1 Metoda bazowa

Jako pierwsza została przetestowana metoda bazowa. Sprawdzono dokładność szacowania wieku zmieniając parametry algorytmu trenującego Fuzzy C-means:

- m - współczynnik rozmycia
- n - liczba iteracji
- g - ilość grup
- ϵ - kryterium (wzór 2.45)

Przykładowy wynik testowania metody został przedstawiony w tabeli 4.1

Dla parametrów $m = 2,0$, $n = 100$, $g = 10$ oraz $\epsilon = 1e-5$ błąd MAE wyniósł 12,75 roku. Następnie zmieniono m do wartości 3.0. Jakość algorytmu szacującego wiek poprawiła się o 1,45 roku i wyniosła 11,3. Ostatnia testowana wartość parametru m wyniosła 5. W wyniku testu MAE wyniósł 11,67 roku.

W kolejnym kroku przetestowano wpływ parametru ϵ dla metody oryginalnej. Dla parametrów: $m = 2,0$, $n = 100$, $\epsilon = 1e-6$ oraz $g = 10$, błąd MAE wyniósł 11,19 roku. Zmiana parametru ϵ do $1e-7$ spowodowała, że parametr MAE wzrósł do 11,24 roku. Dla wartości $1e-8$ parametru ϵ błąd MAE okazał się mieć identyczną wartość 11,24 roku. Należy podkreślić, że liczba iteracji została zmieniona do 1000, ponieważ początkowa wartość ograniczała osiągnięcie żądanej wartości ϵ zarówno dla wartości $\epsilon = 1e-7$, jak i dla $1e-8$.

Następnie testowano wpływ liczby grup. Dla $m = 2,0$, $n = 100$, $g = 20$ oraz $\epsilon = 1e-5$ błąd MAE wyniósł 10,97 roku. W kolejnym kroku zmieniono liczbę grup do 50. Otrzymano MAE w wysokości 10,66 roku. W ostatnim

wiek prawdziwy	wiek wykryty	różnica
10	25	15
15	56	41
16	26	10
16	25	9
17	29	12
19	26	7
1	22	21
20	25	5
20	23	3
22	26	4
22	26	4
25	29	4
26	30	4
26	34	8
26	26	0

Tablica 4.1: Przykładowy wynik testowania zawierający 15 ze 100 wyników.

kroku liczba grup wyniosła 100, natomiast parametr MAE był równy 10,68 roku.

Minimalna wartość MAE dla metody bazowej wyniosła 10,66 roku. Została ona osiągnięta dla $m = 2,0$, $g = 50$, $\epsilon = 1e-5$, $n = 100$

4.5.2 Odjęcie strefy 2

W kolejnym kroku została przetestowana metoda, które nie uwzględnia zmarszczek ze strefy 2. Podobnie jak w sekcji 4.5.1 wykonywano testy dla takich samych parametrów algorytmu Fuzzy C-means. Wyznaczono błąd MAE dla parametrów $m = 2,0$, $n = 100$ oraz $g = 10$, $n = 100$ oraz $\epsilon = 1e-5$. Powyższy błąd wyniósł 13,66 roku. Następnie zmieniono parametr m na wartość 3,0. Parametr MAE dla tej wartości wyniósł 13,74 roku. Ostatnia wartość m wyniosła 5,0. W tym przypadku otrzymano MAE wielkości 14,41 roku.

Następnie analizowano wpływ parametru ϵ . Tak jak w testach z sekcji 4.5.1 na potrzeby analizy należało zmienić parametr n do 1000. Najpierw przetestowano MAE dla wartości $\epsilon = 1e-6$. Wyniosła ona 13,65. Dla wartości

$\epsilon = 1e-7$ parametr MAE był równy 13,77. MAE wyniósł 12,31 roku dla $\epsilon = 1e-8$.

Na samym końcu przeanalizowano wpływ liczby klastrów na MAE. Najpierw zbadano wartość MAE dla 20 grup. MAE wyniósł 13,62. Następnie podwyższono wartość do $g = 50$. Dla powyższej wartości uzyskano MAE 13,61 roku. Ostatnią wartością było $g = 100$ lat. MAE wyniósł 13,74 roku.

Minimalna wartość MAE dla opisywanej modyfikacji wyniosła 12,31 roku. Została ona osiągnięta dla $m = 2,0$, $g = 10$, $\epsilon = 1e-8$, $n = 1000$

4.5.3 Metoda HOG

Kolejną przetestowaną modyfikacją była ta w której użyto algorytmu HOG. Podobnie jak w sekcjach 4.5.2 oraz 4.5.1 modyfikowano parametry algorytmu Fuzzy C-means, jednak dodatkowo dokonano zmiany parametru HOG, Parametrem poddanym modyfikacji był rozmiar komórki. Najpierw ustalono wymiary komórki na 3x3 pikseli. Rozmiar okna wyniósł 6x6 pikseli, natomiast liczba komórek histogramu była stała i wynosiła 9 dla wszystkich pomiarów. Dla komórki 6x6 pikseli rozmiar okna wynosił 12x12 pikseli, natomiast przyjęto rozmiar okna 18x18 pikseli dla komórki równej 9x9 pikseli.

W pierwszym teście ustalono następujące parametry Fuzzy C-means: $m = 2,0$, $n = 100$ oraz $g = 10$, $n = 100$ oraz $\epsilon = 1e-5$. W tym przypadku wartość MAE wyniosła 16,57 roku. Dla wartości komórki równej 6x6 pikseli błąd MAE osiągnął wartość 16,44. Natomiast dla wymiarów komórki równych 9x9 pikseli wartość MAE wyniosła 11,3. Należy podkreślić, że powyższa wartość MAE nie zmieniała się przy modyfikacji parametrów Fuzzy-C means.

Przy zmianie parametru m do 3,0 wartość MAE wyniosła 16,82 roku dla komórki 3x3 pikseli, natomiast 16,73 roku dla komórki 6x6 pikseli. Dla komórki 3x3 pikseli zmiana parametru m do 5,0 zmniejszyła MAE do 16,79 roku, natomiast w przypadku komórki 6x6 pikseli błąd MAE wzrósł do 16,89 roku. Dla parametrów $m = 2,0$ $n = 1000$, $\epsilon = 1e-6$, $g = 10$ oraz komórki 3x3 pikseli MAE wyniósł 16,69 roku, z kolei przy zmianie rozmiarów komórki do 6x6 pikseli wielkość MAE wyniosła 16,44 roku. Dla zmiany parametru ϵ do $1e-7$, MAE wyniósł 16,76 roku przy komórce o wymiarach 6x6 pikseli, a

dla komórki 3x3 pikseli uzyskano MAE 16,49 roku. Dla wartości $\epsilon = 1e-8$ MAE osiągnął 16,44 roku przy rozmiarach komórki 6x6 pikseli, natomiast dla wymiarów 3x3 pikseli wartość MAE wyniosła 16,7 roku.

Dla parametrów $m = 2,0$, $n = 100$ oraz $g = 20$, $n = 100$, $\epsilon = 1e-5$ oraz rozmiaru komórki równej 3x3 pikseli uzyskano MAE równy 16,49 roku, natomiast dla komórki rozmiarów 6x6 pikseli MAE wyniósł 16,77 roku. Przy zmianie g do 50 MAE zmienił wartość do 16,16 roku dla komórki 6x6 pikseli, podczas gdy przy zmianie rozmiaru komórki do 3x3 pikseli MAE był równy 15,89 roku. Dla parametru $g = 100$ oraz komórki 6x6 pikseli MAE wyniósł 16,5 roku, tymczasem dla komórki o wymiarach 3x3 pikseli uzyskano MAE 15,45 roku.

Minimalna wartość MAE dla tej metody wyniosła 11,3 roku. Jak wyżej wspomniano, wartość ta nie była zależna od parametrów algorytmu Fuzzy C-means.

4.5.4 Metoda HOG + KNN

Ostatnią testowaną metodą była ta, która zawiera algorytm HOG, a do klasyfikacji i szacowania używa algorytmu KNN. Zmieniano parametr n dla algorytmu KNN, natomiast dla algorytmu HOG - rozmiary komórki. Parametr n był równy 1, 3 oraz 5. Rozmiary komórki miały wartość 5x5 pikseli, 7x7 pikseli oraz 9x9 pikseli. Liczba komórek histogramu była stała i wynosiła 9. Podobnie jak w Sekcji 4.5.3 zmieniano rozmiary bloku. Dla rozmiaru komórki 5x5 pikseli blok miał wymiary 10x10 pikseli. Blok o rozmiarze 14x14 pikseli był testowany wraz z wartością komórki 7x7 pikseli. Ostatni rozmiar komórki 9x9 pikseli był ustawiany wraz z rozmiarem bloku 18x18 pikseli.

Przy parametrze $n = 1$ oraz wymiarach komórki 5x5 MAE wyniósł 11,75 roku. Przy zmianie parametru do $n = 3$ MAE zmniejszył się do 11,65 roku. Dla ostatniej wartości KNN = 5 MAE był najmniejszy i osiągnął wartość 11,38 roku.

Następnym krokiem było badanie jakości szacowania wieku dla wartości komórki 7x7 pikseli. MAE wyniósł 10,77 roku dla $n = 1$, 10,34 roku dla $n = 3$ oraz 10,56 roku dla $n = 5$.

Jako ostatnie badano komórki o wymiarach 9x9 pikseli, a analiza przyniosła następujące rezultaty: Dla $n = 1$ MAE wyniósł 10,15 roku. Zmiana parametru n do 3 zmieniła MAE do wartości 10,07 roku. Dla ostatniej wartości n równej 5 MAE osiągnął najmniejszą wartość w całym procesie testowania - 9,97 roku.

Rozdział 5

Podsumowanie

Dla metody bazowej zmiany poszczególnych parametrów algorytmu FCM przynosiły nieznaczne zmiany MAE, z wyjątkiem jednej próby. Przy parametrach $m = 2.0$, $n = 100$ $\epsilon = 1e-5$ oraz $g = 10$ MAE wyniósł 12,75 roku. Dla reszty parametrów zmiany MAE mieściły się w zakresie od 10,66 do 11,67 roku. Największe polepszenie wskaźnika MAE uzyskano przy zmianie parametru g na 20 i więcej. Przy powyższej zmianie wartość MAE spadła poniżej 11 lat.

Dla modyfikacji, która polegała na odjęciu strefy nr 2 wyniki znacznie się pogorszyły. Modyfikacja parametru m pogarszała wskaźnik MAE do wartości od 13,66 do 14,41 roku. Minimalna wartość MAE została osiągnięta dla parametrów $m = 2.0$, $n = 1000$ $\epsilon = 1e-8$ oraz $g = 10$. Warto zaznaczyć, że modyfikacja liczby klastrów nie polepszyła MAE tak jak w przypadku testowania metody bazowej.

W metodzie zawierającej modyfikację z algorytmem HOG przetestowano 27 kombinacji parametrów - 3 razy więcej niż przy testowaniu metody bazowej. W porównaniu do metody z odjętą strefą MAE uległo znacznemu pogorszeniu. Dla komórki o rozmiarach 3x3 pikseli parametry Fuzzy C-means nie dawały znacznej poprawy rezultatów MAE. Wskaźnik MAE osiągał wartości od 15,45 do 16,82 roku. Podobne wartości były osiągane dla komórki o rozmiarach 6x6 pikseli. W tym przypadku MAE mieściło się w zakresie od 16,16 do 16,89 roku.

Ostatnia modyfikacja przyniosła poprawę w porównaniu do metody bazowej. Dla rozmiaru komórki 5x5 pikseli oraz dla zmiennego parametru n algorytmu KNN błąd MAE osiągał wartości od 11,38 do 11,75 roku. Warto zauważyć, że poprawa wskaźnika MAE następowała wraz ze wzrostem parametru n . Zmiana rozmiaru komórki na 7x7 polepszyła wskaźnik MAE. Osiągał on wartości od 10,34 do 10,77 roku. W tym przypadku najlepszą wartość MAE spośród wszystkich przetestowanych osiągnięto dla wartości $n = 3$, czyli wartości pośredniej. Najlepsze wartości osiągnięto dla komórki o rozmiarach 9x9 pikseli. Minimalną i zarazem najlepszą dla wszystkich testów wartość osiągnięto dla parametru $n = 5$.

Testowanie metody bazowej oraz jej modyfikacji wykazało, że wskaźnik MAE oscylował w granicach 10 lat. Nie jest to wartość zadowalająca, gdyż w literaturze ten wskaźnik osiągał wartości około 5 lat. [14] Natomiast udało się polepszyć algorytm bazowy. Modyfikacja zawierająca algorytm HOG oraz KNN poprawiła MAE z 10,66 do 9,97 roku. W celu poprawy wyników należałoby zwiększyć bazę treningową. Z ponad 20000 obrazów zamieszczonych w bazie tylko 2574 brało udział w treningu. Wiele zdjęć zostało odrzuconych z powodu braku rozpoznania przez detektor oczu oraz nosa. W związku z powyższym należałoby użyć lepszych detektorów lub znaleźć bazę, która zawiera zdjęcia twarzy o lepszej jakości.

Bibliografia

- [1] T. F. Cootes A. Lanitis, Ch. J. Taylor. *Toward automatic simulation of aging effects on face images*. IEEE Transactions of Pattern Analysis and Machine Intelligence, 2002.
- [2] Abid K. Alexander Mordvintsev. Face Detection using Haar Cascades . https://opencv-python-tutroals.readthedocs.io/en/latest/py_tutorials/py_objdetect/py_face_detection/py_face_detection.html, 2019. [Online; Dostęp: 28.09.19].
- [3] Munish Kumar Ashu Kumar, Amandeep Kaur. *Face detection techniques: a review*. Springer, 2018.
- [4] BADGERATI. <https://computersciencesource.wordpress.com/2010/09/03/computer-vision-the-integral-image/>, 2010. [Online; Dostęp: 28.09.19].
- [5] Pawel Cichosz. *Data Mining Algorithms: Explained Using R*. Wiley, 2014.
- [6] Coutaz J Crowley JL. *Vision for man-machine interaction*. Robotics and Autonomous Systems, 1997.
- [7] Navneet Dalal, Bill Triggs. *Histograms of Oriented Gradients for Human Detection*. Conference on Computer Vision Pattern Recognition, 2005.
- [8] M.M. Dehshibi, A. Bastanfard. *A new algorithm for age recognition from facial images*. Signal Processing, 2010.
- [9] Brian Everitt. *Cluster analysis*. Wiley, 2011.

- [10] Erik Fritts. <https://www.videomaker.com/article/c03/18848-tell-your-story-more-effectively-with-the-correct-application-of-hard-and-soft-light>, 2017. [Online; Dostęp: 07.10.19].
- [11] Alvaador Garcia, Joaquin Derrac, Jose Cano, Francisco Herrera. *Prototype Selection for Nearest Neighbor Classification: Taxonomy and Empirical Study*. IEEE, 2012.
- [12] Noor A. Ibraheem, Mokhtar M. Hasan, Rafiqul Z. Khan, Pramod K. Mishra. *Understanding Color Models: A Review*. ARPN Journal of Science and Technology, 2012.
- [13] Scott Kelby. *Sekrety mistrza fotografii cyfrowej*. Helion, 2014.
- [14] Vladimir Khryashchev, Alexander Ganin, Olga Stepanova, Anton Lebedev. *Age Estimation from Face Images: Challenging Problem for Audience Measurement Systems*. Yaroslavl State University, 2014.
- [15] Wan-Chi Siu Kwok-Wai Wong, Kin-Man Lam. *Age Estimation from Face Images: Challenging Problem for Audience Measurement Systems*. Centre for Multimedia Signal Processing, Department of Electronic and Information Engineering, The Hong Kong Polytechnic University, Hung Hom, Hong Kong, 2000.
- [16] Dominik Ślęzak, Jakub Wróblewski. <http://edu.pjwstk.edu.pl/wyklady/adn/scb/wyklady>, 2006. [Online; Dostęp: 26.10.19].
- [17] Xiaoju Ma, Bo Li, Ying Zhang, Ming Yan. *The Canny Edge Detection and Its Improvement*. Springer, 2012.
- [18] Satya Mallick. <https://www.learnopencv.com/histogram-of-oriented-gradients/>, 2016. [Online; Dostęp: 21.10.19].
- [19] Robert K. McConnell. Method of and apparatus for pattern recognition, 1982. Patent nr US4567610.
- [20] Henrik Skov Midtiby. Example: Rgb color mixing, 2019. [Online; Dostęp: 28.09.19].

-
- [21] R. Chellappa N. Ramanathan. *Face verification across age progression*. IEEE Transactions on Image Processing, 2006.
- [22] Avinash Navlani. <https://www.datacamp.com/community/tutorials/k-nearest-neighbor-classification-scikit-learn>, 2018. [Online; Dostęp: 22.10.19].
- [23] Michael Jones Paul Viola. *Rapid Object Detection using a Boosted Cascade of Simple Features*. Accepted conference on computer vision and pattern recognition, 2001.
- [24] Rituparna Sahaa Ranjan Janaa, Debaleena Dattaa. *Age Estimation from Face Image using Wrinkle Features*. RCC Institute of Information Technology, 2014.
- [25] Qaim Mehdi Rizvi. *A Review on Face Detection Methods*. Qassim University, 2011.
- [26] Peter M. Roth, Helmut Grabner, Christian Leistner, Horst Bischof, Martin Winter. *Interactive learning a person detector: fewer clicks – less frustration*. Researchgate, 2008.
- [27] Przemyslaw Spurek. <http://analizaobrazu.x25.pl/articles/11>, 2018. [Online; Dostęp: 19.10.19].
- [28] Richard Szeliski. *Computer Vision: Algorithms and Applications*. Springer, 2011.
- [29] Piotr Wilkowski. *Wykorzystanie algorytmu detekcji i lokalizacji w zadaniu chwywania*. Politechnika Warszawska, Wydział Elektroniki i Technik Informacyjnych, 2009.
- [30] K. Smith-Miles X. Geng, Z. Zhou. *Automatic age estimation based on facial aging patterns*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2007.
- [31] N. da V. Lobo Y. H. Kwon. *Age classification from facial images*. *Computer Vision and Image Understanding*. 1999.

Dodatki

Dokumentacja techniczna

Program został zrealizowany zarówno w programie Java oraz Matlab.

Funkcje Java

$[dane_trenigowe] = generateDataFromImagesAuto()$

Funkcja generuje dane treningowe według jednego z algorytmów

Dane wejściowe:

propertiesLoader	PropertiesLoader	Klasa PropertiesLoader zawierająca ścieżkę do obrazów treningowych oraz konfigurację algorytmów generujących wskaźnik zmarszczek
------------------	------------------	--

Dane wyjściowe:

<i>dane_trenigowe</i>	File	Plik zawierający dane wygenerowanych wskaźników zmarszczek
-----------------------	------	--

$[wiek] = \text{recognizeAge}()$

Funkcja szacująca wiek na podstawie danych wygenerowanych z algorytmu FCM oraz danego obrazu.

Dane wejściowe:

path	String	Ścieżka do obrazu, z którego szacowany jest wiek
age2centers	String	Ścieżka do centroidów wygenerowanych z algorytmu FCM

Dane wyjściowe:

<i>wiek</i>	int	Szacowany wiek z danego obrazu
-------------	-----	--------------------------------

Funkcje Matlaba

$[age2centers] = \text{clusterToFuzzyCMeans}()$

Funkcja generująca centroidy z wykorzystaniem algorytmu Fuzzy C-means na podstawie danych z treningu (wygenerowane za pomocą funkcji `generateDataFromImagesAuto()`)

Dane wejściowe:

<i>dane_treningowe</i>	File	Dane z treningu wygenerowane za pomocą funkcji <code>generateDataFromImagesAuto()</code>
------------------------	------	--

Dane wyjściowe:

<i>age2centers</i>	File	Centroidy niezbędne do szacowania wieku w funkcji <code>recognize-Age()</code>
--------------------	------	--

`[wiek_szacowany] = knnHog59()`

Funkcja trenująca i szacująca wiek dla metody HOG + KNN.

Dane wejściowe:

KnnHog59	File	Plik z danymi treningowymi. Dane wygenerowane za pomocą algorytmu HOG, w którym komórka miała rozmiary 5x5 piksela
TrainKnnHog59	File	Plik z danymi testowymi

Dane wyjściowe:

<i>wiek_szacowany</i>	File	Plik zawierający wiek szacowany dla danych testowych dla parametrów $k=1,3,5$ algorytmu KNN
-----------------------	------	---

$[wiek_szacowany] = knnHog79()$

Funkcja trenująca i szacująca wiek dla metody HOG + KNN.

Dane wejściowe:

KnnHog79	File	Plik z danymi treningowymi. Dane wygenerowane za pomocą algorytmu HOG, w którym komórka miała rozmiary 7x7 piksela
TrainKnnHog79	File	Plik z danymi testowymi

Dane wyjściowe:

<i>wiek_szacowany</i>	File	Plik zawierający wiek szacowany dla danych testowych dla parametrów $k=1,3,5$ algorytmu KNN
-----------------------	------	---

$[wiek_szacowany] = knnHog99()$

Funkcja trenująca i szacująca wiek dla metody HOG + KNN.

Dane wejściowe:

KnnHog79	File	Plik z danymi treningowymi. Dane wygenerowane za pomocą algorytmu HOG, w którym komórka miała rozmiary 9x9 piksela
TrainKnnHog99	File	Plik z danymi testowymi

Dane wyjściowe:

<i>wiek_szacowany</i>	File	Plik zawierający wiek szacowany dla danych testowych dla parametrów $k=1,3,5$ algorytmu KNN
-----------------------	------	---

Spis skrótów i symboli

FCM - *Fuzzy C-means* - metoda klasteryzacji miękkiej (rozmytego).

HOG - *Histograms of Oriented Gradients* - metoda generacji deskryptora obrazu

KNN - *k-Nearest Neighbors* - algorytm regresji lub klasyfikacji.

MAE - *Mean Absolute Error* - średni błąd bezwzględny

BIF - *Biologically Inspired Features* - detektor cech o charakterze biologicznym

LBP - *Local Binary Patterns* - detektor cech (lokalnych wzorców binarnych)

FPR - *False Positive Rate* - współczynnik fałszywych klasyfikacji, jako obiekt.

TP - *True Positive* - poprawna klasyfikacja, jako obiekt

TN - *True Negative* - poprawna klasyfikacja, jako nie - obiekt

FP - *False Positive* - błędna klasyfikacja jako obiekt

FN - *False Negative* - błędna klasyfikacja jako nie - obiekt

INRIA - *Institut National de Recherche en Informatique et en Automatique*
- francuski instytut zajmujący się badaniami w zakresie informatyki i automatyki

Zawartość dołączonej płyty

Do pracy dołączona jest płyta CD z następującą zawartością:

- praca w formacie pdf,
- źródła programów .m i główna klasa generująca wskaźnik zmarszczek w formacie .java
- wersja elektroniczna pracy:
 - wersja kompletna
 - wersja bez spisu treści, bibliografii, tabel, załączników oraz rysunków
- wyniki działania programów

Spis rysunków

1.1	Przykład rozpoznawania osób na obrazie [26].	2
2.1	Faza 1 algorytmu	7
2.2	Faza 2 algorytmu	7
2.3	Przykład twarzy oświetlonej ostrym (twarz po lewej) oraz mię- kim światłem [10].	9
2.4	Różne techniki wykrywania twarzy [3].	10
2.5	Mieszanie kanałów RGB [20].	13
2.6	Kolor R=153 G=217 B=234.	13
2.7	Filtr Haara a) krawędziowy b) liniowy c) szachownica [2] . . .	14
2.8	Filtr Haara nałożony na krawędź twarzy [2]	15
2.9	Tabela jasności poszczególnych pikseli przed zastosowaniem całkowania [4]	16
2.10	Filtr Haara nałożony na krawędź twarzy [4]	16
2.11	Sumowanie okna [4]	17
2.12	Kaskada klasyfikatorów [29].	19
2.13	Macierz pomyłek.	20
2.14	Wykryty nos oraz oczy.	21
2.15	Strefy zmarszczkowe widoczne w białych prostokątach.	22
2.16	Wyznaczenie strefy znajdującej się na czole.	23
2.17	Pomocnicze współrzędne do wyliczania stref zmarszczkowych.	23
2.18	Punkty wyznaczające położenie stref.	24
2.19	a) Obraz z nieznaczną ilością szumów b) Obraz ze znaczną ilością szumów [27].	28
2.20	a) Oryginalny obraz b) Obraz z wykrytymi krawędziami. . . .	31

3.1	Gradient jasności identyfikujący granicę pomiędzy głową a tłem [18].	39
3.2	Komórki o rozmiarze 8x8 pikseli na zdjęciu [18].	40
3.3	Komórki o rozmiarze 8x8 pikseli na zdjęciu [18].	41
3.4	Przykład klasyfikacji KNN [22].	49
4.1	Przykład prawidłowej detekcji zmarszczek. a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek	56
4.2	Przykład nieprawidłowej detekcji zmarszczek w strefie 2. a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek	56
4.3	Przykład nieprawidłowej detekcji zmarszczek w strefie 1. a) Obraz przed detekcją zmarszczek b) Obraz po detekcji zmarszczek	57

Spis tablic

4.1	Przykładowy wynik testowania zawierający 15 ze 100 wyników.	62
-----	---	----